从点云进行表面重建：综述与基准

Surface Reconstruction From Point Clouds:
A Survey and a Benchmark

ZhangJin Huang · Yuxin Wen · ZiHao Wang · Jinjuan Ren · Kui Jia

IEEE Transactions on Pattern Analysis and Machine Intelligence
2024 年第 46 卷第 12 期，9727–9748 页

> 中文阅读辅助译稿。正文、图注及作者简介按原文翻译；图表和公式保留原图，并配中文标题与说明。参考文献保留英文题录，方便检索。

使用方法

建议先读配套导读，再按需要查阅本译稿。各部分标有原文 PDF 页码，文中的参考文献编号、方法名称和公式编号与原文对应。图内英文标签保留，主要含义见中文图注。

译稿采用便于阅读的单栏排版，保留原文层级、编号和图表内容。译文与导读分开：本文件转述原文，阅读建议在另一文件中。

时间定位

原文首次在线发表于 2024 年 7 月 16 日；稿件于 2022 年提交、2023 年修订。它适合作为基础框架和基准阅读，近期前沿需另用 2025–2026 年论文补充。

章节导航（原文 PDF 页码）

I 引言：1–4
II 问题定义：4–5
III 几何先验分类：5–9
IV 重建基准：10–13
V 实验设置：13–14
VI 主要结果：14–18
VII 结论：18–19
参考文献与作者简介：19–22

原文 PDF 第 1 页 · 期刊页 9727

点云表面重建：综述与基准评测

ZhangJin Huang、Yuxin Wen、ZiHao Wang、Jinjuan Ren 和 Kui Jia

（综述论文）

摘要

从原始、离散的点云观测中重建作为二维流形的连续表面，是计算机视觉与图形学研究中一个长期存在的问题。从技术上说，该问题是不适定的；考虑到实际深度扫描得到的点云会出现各种感知缺陷，这一问题就更加困难。已有文献提出了丰富的方法，也提供了对现有方法的综述。然而，现有综述缺乏在统一基准上的深入考察。本文旨在深度学习表面重建的新时代，对现有方法进行综述和基准评测。为此，我们贡献了一个由合成数据和真实扫描数据共同组成的大规模基准评测数据集；该基准包含对象级和场景级表面，并考虑了实际深度扫描中常见的各种感知缺陷。我们在构建的基准上对现有方法进行比较，开展了深入的实证研究，尤其关注现有方法对各种扫描缺陷的鲁棒性；我们还研究了不同方法在重建复杂表面形状时的泛化表现。这些研究有助于确定不同方法最适合的工作条件，并得出了一些实证发现。例如，尽管深度学习方法在研究群体中日益流行，我们的系统研究却令人意外地表明，一些经典方法在鲁棒性和泛化能力两方面的表现甚至更好；我们的研究还表明，多视角扫描点集的错位、表面点缺失以及离群点等实际挑战，仍未被任何现有表面重建方法解决。我们期望这一基准及相关研究既能为实际应用者提供价值，也能为未来研究中的新创新提供指引。

索引词——表面重建、表面建模、点云、基准评测数据集、文献综述、深度学习。

I. 引言

对象或场景表面的建模与重建，是计算机视觉和图形学研究中的基础问题。其应用涵盖虚拟 / 增强现实、计算机动画、计算机辅助设计以及机器人学。从数学本质上看，表面形状是嵌入三维欧氏空间中的连续二维流形，因此，在采集、传输和存储表面形状时，通常采用不同的近似表示，其中典型的例子包括点云、多边形网格和量化体数据。本文特别关注从离散的点云近似表示中重建连续表面，因为许多深度传感器，例如基于多视角立体视觉、结构光或飞行时间测量的传感器，直接以点云，或等价的深度图，作为原始数据采集形式；随后，各种下游应用都需要从所获得的点云中重建表面。

从技术上说，这一问题是不适定的——给定一组观测到的离散点，其背后的连续表面可能有无穷多种解。考虑到数据采集过程中会出现各种感知缺陷，挑战就更加严峻：采集到的点云可能含有噪声且分布不均匀，可能包含离群点，和 / 或在某些表面区域覆盖不足；当点云从多个视角采集时，不同点云之间的对齐也可能不够准确。这些问题使得从点云重建表面这一经典问题成为长期挑战，持续吸引着研究群体投入研究。

针对这一研究问题，已有文献提出了丰富的方法。这些方法根据各自假设的数据缺陷类型，利用不同的表面几何先验来应对原本不适定的问题。尽管文献 [1]、[2]、[3]、[4] 已对这些方法作了全面综述，但仍缺乏在统一基准上的考察和分析，以区分现有方法在应对上述数据缺陷时的表现。

稿件信息：2022 年 4 月 18 日收到；2023 年 4 月 6 日修订；2024 年 7 月 8 日接受；2024 年 7 月 16 日发表；当前版本日期为 2024 年 11 月 5 日。研究得到广东省人类数字孪生重点实验室资助，项目编号 2022B1212010004。由 K. M. Lee 推荐接受。ZhangJin Huang 与 Yuxin Wen 对本工作贡献相同。通讯作者：Kui Jia。

作者单位：ZhangJin Huang、Yuxin Wen、ZiHao Wang 和 Kui Jia，华南理工大学电子与信息学院，中国广州 510641；电子邮件分别为 eehuangzhangjin@mail.scut.edu.cn、wen.yuxin@mail.scut.edu.cn、eezihaowang@mail.scut.edu.cn、kuijia@gmail.com。Jinjuan Ren，澳门大学，中国澳门 314100；电子邮件：jinjuanren@um.edu.mo。

基准公开地址：https://Gorilla-Lab-SCUT.github.io/SurfaceReconstructionBenchmark。作者提供的可下载补充材料见 https://doi.org/10.1109/TPAMI.2024.3429209。数字对象标识符（DOI）：10.1109/TPAMI.2024.3429209。

0162-8828 © 2024 IEEE。允许个人使用，但再次出版或重新分发需要 IEEE 许可。更多信息见 https://www.ieee.org/publications/rights/index.html。

原文 PDF 第 2 页 · 期刊页 9728

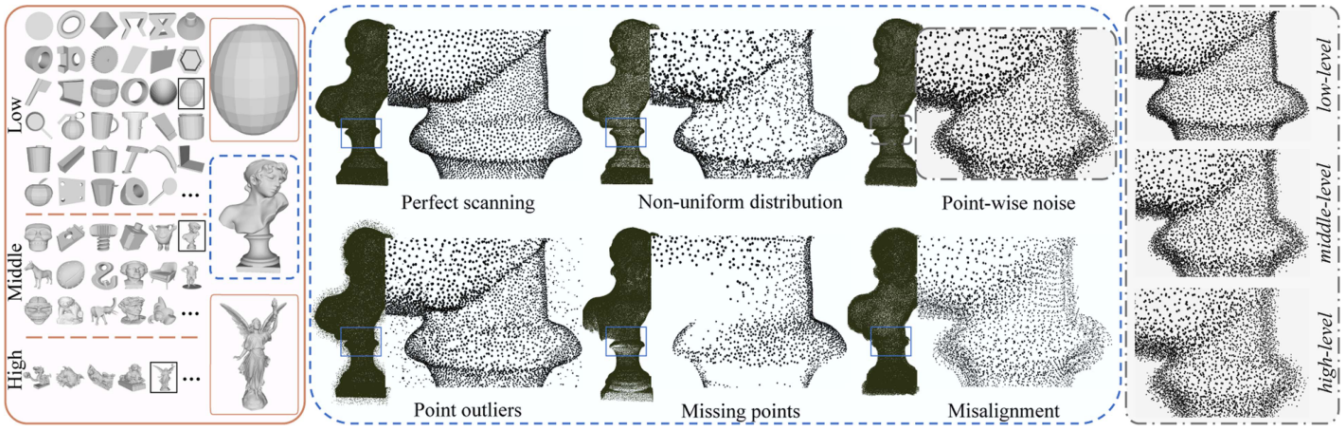


图 1. 本文所贡献基准中不同表面复杂度与扫描挑战的示意。从左至右分别为：低、中、高复杂度的对象表面示例；实际表面扫描中可能遇到的五种挑战；以及含噪扫描这一挑战的不同严重程度示例。

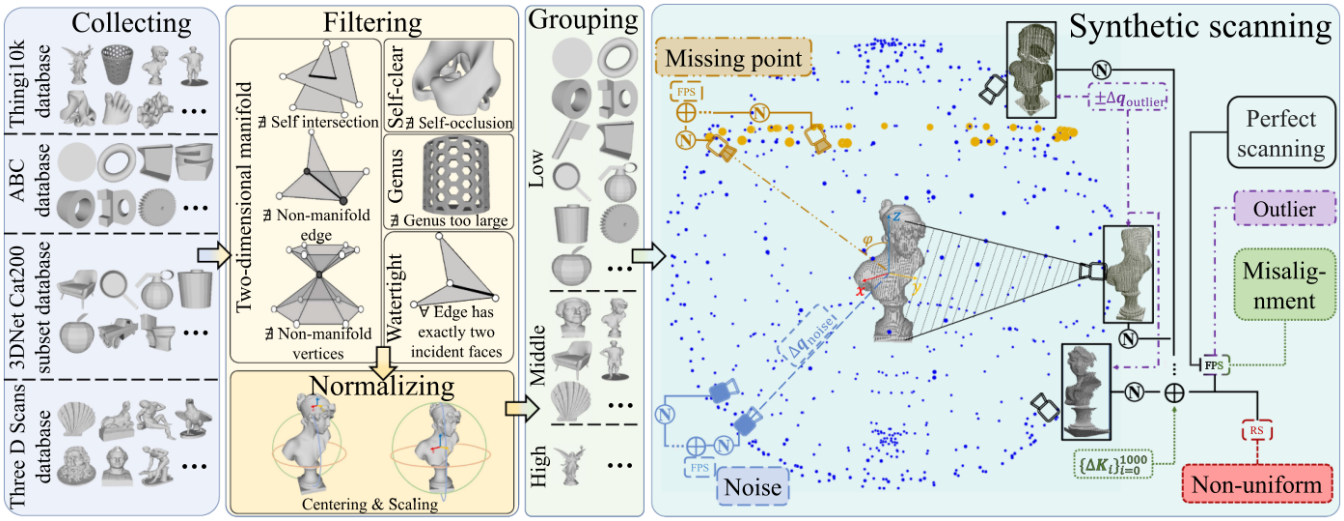


图 2. 合成对象级数据集的构建流程，详见第 IV-A 节。首先从四个模型库收集对象表面的 CAD 模型，如图最左侧所示。随后筛选所收集的表面，剔除不符合要求的模型，并对其余模型进行归一化，如图中部所示。再根据（代数）表面复杂度这一准则，将归一化后的对象表面分成低、中、高复杂度三组，比例约为 6：3：1。最后进行合成扫描，如图右侧所示，模拟实际扫描中可能出现的不同挑战。蓝色点表示视球上的扫描位置；估计定向法向后，图中以 N 表示法向，我们对不同扫描视角之间的点云进行配准，得到最终扫描点云。除另有说明而采用随机采样（RS）的情况外，我们使用最远点采样（FPS），从每份点云中采样固定数量的点。

与此同时，该领域近来出现了深度学习表面重建的研究热潮：通过学习并使用深度网络模型，或者从点云中显式解码表面形状 [5]、[6]、[7]，或者生成隐式场，再从中提取零水平等值面作为表面重建结果 [8]、[9]、[10]。因此，需要同时对经典方案与较新的深度学习方案进行基准评测，以理解它们各自的优势与局限。这样的考察无疑有助于实际应用者选择合适的方法，也能为未来研究中的新创新提供指引。

本文旨在深度学习表面重建的新时代，全面综述并评测现有方法。我们按照现有方法用于约束重建结果的表面几何先验组织综述：除了经典的基于优化的先验，还纳入了较新的深度模型和深度学习先验。我们的关键贡献之一，是一个由合成数据和真实扫描数据共同组成的大规模基准评测数据集，其构建方式的示意见图 2、图 3 和图 5。该基准包含对象级和场景级表面，并考虑实际三维扫描所得点云中常见的各种感知缺陷，例如逐点噪声、表面点分布不均匀、离群点、表面点缺失，以及多视角扫描点集的错位；图 1 展示了这些扫描缺陷。我们在所构建的基准上开展深入的实证研究，比较现有方法从观测点云重建表面的能力。我们尤其关注现有方法对各种扫描缺陷的鲁棒性；同时，我们还研究不同方法在重建复杂表面形状时的泛化能力。深入研究使我们能够从多个角度识别现有方法的优势与局限。下面总结几项重要发现。

原文 PDF 第 3 页 · 期刊页 9729

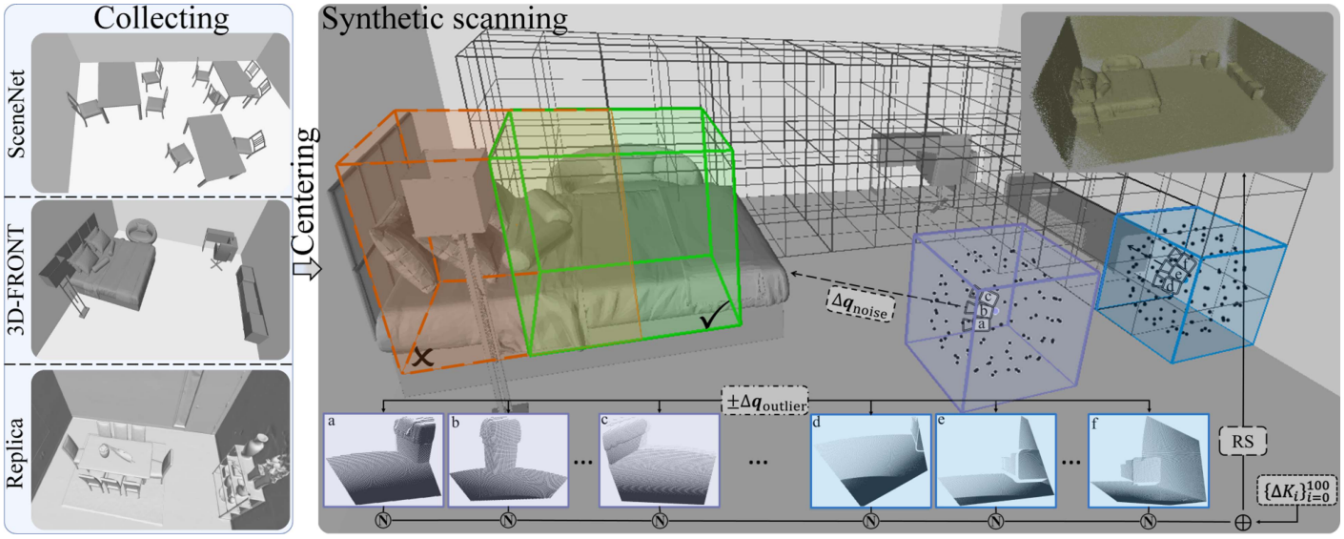


图 3. 合成场景级数据集的构建流程，详见第 IV-B 节。我们从三个数据集收集室内场景的 CAD 表面模型，如图左侧所示，并通过将模型中心置于三维空间原点来进行归一化。随后将三维空间划分为相互重叠的立方体，如图右侧所示；其中一些立方体包含场景表面的局部片，另一些则为空。相机被放置在这些空立方体的中心，例如紫色和蓝色立方体；对于每个已放置的相机，我们随机采样 100 个视角进行扫描。场景表面的每次扫描都包含实际扫描的五种挑战，各项挑战的具体实现与合成对象扫描中的实现相似。

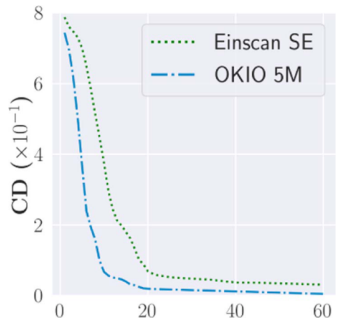


图 4. Chamfer 距离（CD）与扫描次数之间的关系。计算 CD 时，以 OKIO 5 M 的 100 次扫描结果作为真值。



图 5. 真实扫描数据集中所用对象的示意。对象按材料类型组织，其中 a 为塑料对象，b 为陶瓷对象，c 为布料对象，d 为金属对象。

• 尽管从点云重建表面的许多挑战能被现有方法不同程度地应对，错位、点缺失和离群点这些问题受到的处理仍较少，尚未解决。

• 深度学习方案近来在表面建模与重建方面显示了很大潜力；然而，我们的系统研究表明，它们难以泛化到复杂形状的重建。令人意外的是，一些经典方法在泛化能力和鲁棒性两方面的表现甚至更好。

• 使用表面法向，是成功从原始观测点云重建表面的关键，即使法向估计不够准确也是如此。在许多情况下，只要能够在三维空间中区分表面内部与外部，结果就会改善。

• 不同评价指标之间存在不一致；在许多情况下，良好的定量结果并不总是与视觉上令人满意的结果相一致。这表明，需要开展更多基础性研究，以更好地评测不同方法并推动该领域发展。

A. 相关工作

本节概述从点云或其他观测中重建表面的已有文献，并总结用于推动该领域发展的现有数据集和基准。

从点云进行表面重建

已有大量方法研究从点云重建表面。文献 [1]、[2]、[3]、[4]、[11] 对这些方法进行了综述。较早的综述 [1] 和 [2] 按照所使用的表面表示函数组织现有方法，例如隐式或显式函数。较新的文献 [4] 则根据所用技术的不同对方法分类，包括插值和逼近技术、基于学习的技术以及软计算技术。晚于我们工作的最新研究 [11] 将方法分为基于表面和基于体的两类。

原文 PDF 第 4 页 · 期刊页 9730

本文的综述组织方式与文献 [3] 更为相似，后者同样根据所使用的几何先验组织现有方法。与文献 [3] 相比，我们的综述更全面，纳入了近期的深度学习表面重建方法。此外，我们还在一个基准上对现有方法进行了实证比较，从而有助于识别现有方法各自的优势与局限。

更一般的表面建模与重建

表面重建也可以基于其他原始观测完成，例如单视角或多视角图像、运动信息，和 / 或光照与明暗信息。文献 [12]、[13]、[14] 对传统多视角图像重建方法进行了综述。较新的文献 [15] 综述了利用深度学习进行多视角图像重建的方法。Fahim 等人 [16] 关注更具挑战性的设定，即仅凭少至一张图像，通过深度学习重建表面。Zhu 等人 [17] 对三维建模方法作了更全面的综述，包括多视角三维重建、运动恢复结构，以及明暗恢复形状。与上述综述不同，考虑到深度传感器正越来越广泛地部署在便携或固定设备中，本文重点研究从原始观测点云重建表面。

数据集与基准

现有支持表面重建研究的数据集基于合成或真实扫描数据，可能包含对象级和 / 或场景级表面。对于合成数据集，通常提供表面网格，以便从中采样点云。例如，ShapeNet [18] 和 ModelNet [19] 是两个常用的合成数据集，由简单的对象级形状组成。3DNet [20]、ABC [21]、Thingi10k [22] 和 Three D Scans [23] 则提供更复杂的合成对象表面。SceneNet [24] 和 3D-FRONT [25] 提供合成场景级表面。与此同时，也有真实扫描的对象级表面数据集 [26]、[27]、[28]，以及真实扫描的场景级表面数据集 [29]、[30]；不过，由于缺乏高精度扫描，其重建真值通常通过适当的表面重建算法获得，这削弱了它们用于评测不同方法的作用。上述大多数数据集没有考虑实际扫描点云中可能出现的感知缺陷，文献 [31] 是一个例外，它使用虚拟扫描模拟点云缺陷；然而，数据集 [31] 规模较小，仅有八个对象表面实例。后续工作 [11] 使用其合成扫描方法，仅在现有对象级数据集上评测方法。相比之下，我们贡献的基准评测数据集更全面，既包含合成数据，也包含真实扫描数据，同时覆盖对象级和场景级表面；我们有意在数据集点云中注入各种感知缺陷，包括逐点噪声、表面点分布不均匀、离群点、表面点缺失以及多视角扫描点集之间的错位。我们期望这一基准能够促进未来研究开展更深入的考察。

B. 贡献

如第 I 节所述，随着深度学习表面重建研究的兴起，本文旨在全面综述新时代的现有方法，并研究这些方法从原始观测点云重建对象级或场景级表面时各自的优缺点。为此，我们贡献了一个由合成数据和真实扫描数据共同组成的大规模基准。我们利用所构建的基准，对现有方法进行系统研究，重点关注这些方法对各种数据缺陷的鲁棒性，以及现有方法在重建复杂表面时的泛化能力。主要贡献总结如下。

• 我们全面综述现有表面重建方法，将经典的基于优化的方法与较新的基于深度学习的方法联系起来，并按照这些方法用于约束解的表面几何先验进行分类。

• 我们贡献了一个包含合成数据与真实扫描数据的大规模基准评测数据集。基准中的点云包含实际三维扫描过程中常见的各种感知缺陷；我们有意纳入这些缺陷，以评测现有方法的鲁棒性。

• 我们在所构建的基准上开展深入的实证研究，比较现有方法。研究帮助识别现有方法的优势与局限，对实际应用者选择适当方法，以及指引未来研究中新创新的方向，都具有价值。

C. 论文结构

本文的组织如下。第 II 节给出所研究问题的形式化定义。第 III 节根据现有方法用于约束重建结果的表面几何先验，组织并综述这些方法。第 IV 节介绍我们贡献的大规模基准，包括基准构建方式的细节和统计信息；基准本身、基准构建方式以及代表性方法的实现代码，均在 https://Gorilla-Lab-SCUT.github.io/SurfaceReconstructionBenchmark 公开。第 V 节说明实证研究的实验设置，第 VI 节随后给出结果、分析和重要见解。最后，第 VII 节对全文作出结论。

II. 问题定义

考虑一个离散点集 P，它可以通过某些三维感知设备扫描对象或场景表面获得；其中每个点 $p \in \mathbb{R}^3$ 表示其在欧氏空间中的坐标。我们关注的目标，是恢复这些点 {p∈P} 实际所观测到的、背后的连续表面 S*。由于从离散的 P 恢复连续的 S* 是一个不适定问题，必须施加适当的正则化，才能得到符合几何特征的近似表面 S，例如平滑和 / 或匀顺的曲面 [32]。

原文 PDF 第 5 页 · 期刊页 9731

形式上，这相当于求解如下正则化优化问题：

$$\min_{\mathcal{S}} L(\mathcal{S};\mathcal{P}) + \lambda R(\mathcal{S}), \qquad (1)$$

其中，L 是保持与观测点集 P 数据保真性的损失项，R 是利用某种表面几何先验约束解的正则项，λ 是标量惩罚系数。[1] 注意，目标式（1）只是抽象形式，因为很难直接在 S 上定义 L 和 R。在实践中，表面可以显式表示为参数映射 $f: \Omega^2 \to S$，其中 $\Omega^2 \subset \mathbb{R}^2$ 表示二维定义域，$S=\{f(x) \in \mathbb{R}^3\}$，$x \in \Omega^2$；也可以隐式表示为隐式函数 $F: \mathbb{R}^3 \to \mathbb{R}$ 的零水平集，即 $S=\{q \in \mathbb{R}^3 \mid F(q)=0\}$。对应地，可以将目标式（1）具体化为以下形式，通过优化显式映射来求得 S：

$$\min_{\boldsymbol{f} \in \mathcal{H}_{\boldsymbol{f}}} L^{\exp}(\boldsymbol{f};\mathcal{P}) + \lambda R^{\exp}(\boldsymbol{f}), \qquad (3)$$

其中，L^{exp} 和 R^{exp} 分别是具体化的损失函数和正则项；还可以选择将 f 约束在假设空间 H_f 中，例如选择神经网络作为 f。另一种方式，是将目标式（1）具体化为以下形式，求得 S 的隐式表示：

$$\min_{F \in \mathcal{H}_F} L^{\mathrm{imp}}(F;\mathcal{P}) + \lambda R^{\mathrm{imp}}(F), \qquad (4)$$

其中，L^{imp} 和 R^{imp} 同样是具体化的函数，H_F 表示可选择用于约束隐式函数 F 的假设空间。除非另有说明，后续各节均使用表 I 中定义的符号。

表 1

Notation	Description
$\mathcal{S}^*$	An underlying surface to be recovered; $\mathcal{S}^* \subset \mathbb{R}^3$.
$\mathcal{S}$	A reconstructed surface; $\mathcal{S} \subset \mathbb{R}^3$.
$\mathcal{G}_{\mathcal{S}}$	A triangular mesh representation of surface $\mathcal{S}$. A mesh with $n_{\mathcal{G}}$ faces is collectively written as $\mathcal{G}_{\mathcal{S}} \triangleq \{\mathcal{T}_i\}_{i=1}^{n_{\mathcal{G}}}$, where each face $\mathcal{T}$ is specified by $\{\boldsymbol{v}_1, \boldsymbol{v}_2, \boldsymbol{v}_3\}$ containing three vertices; we also write as $\boldsymbol{e}_{ij}$ for the edge connecting vertices $\boldsymbol{v}_i$ and $\boldsymbol{v}_j$.
$\mathcal{P}$	A set of $n_{\mathcal{P}}$ discrete points $\{\boldsymbol{p}_i \in \mathbb{R}^3\}_{i=1}^{n_{\mathcal{P}}}$, representing the practical sampling of an underlying surface $\mathcal{S}^*$.
$\boldsymbol{n_p}$	An estimated, oriented surface normal defined at a surface point $\boldsymbol{p}$; $\boldsymbol{n_p} \in \mathbb{R}^3$.
$\mathcal{N}(\boldsymbol{p})$	A local neighborhood of points centered at $\boldsymbol{p}$.
Ω	A domain of subset space, *e.g.* , $\Omega^k \subset \mathbb{R}^k$.
$\mathcal{C}^k$	The smoothness of a function, where k is the number of continuous derivatives the function has over some domain.
$d(\boldsymbol{p})$	A signed or unsigned distance field value at a point $\boldsymbol{p}$.
$\boldsymbol{f_\theta}$ or $F_{\boldsymbol{\theta}}$	An explicit or implicit model of surface reconstruction parameterized by $\boldsymbol{\theta}$ (e.g., a neural network); the parameters are also denoted as $\boldsymbol{\theta_f}$ or $\boldsymbol{\theta}_F$.
$\nabla_x \boldsymbol{f_\theta}$ or $\nabla_x F_{\boldsymbol{\theta}}$	Model derivative with respect to x.
$L(\mathcal{S}; \mathcal{P})$	Loss function of a reconstructed surface $\mathcal{S}$ for data fidelity to an observed $\mathcal{P}$.
$R(\mathcal{S})$	Regularizer imposed on a reconstructed surface $\mathcal{S}$.
$\boldsymbol{K}$	Extrinsic matrix of a camera.

表 I. 数学符号

符号 | 说明

S* | 待恢复的潜在表面；S*⊂ℝ³。

S | 重建表面；S⊂ℝ³。

G_S | 表面 S 的三角网格表示。具有 n_G 个面的网格整体记为 G_S≙{T_i}_{i=1}^{n_G}；每个面 T 由三个顶点 $\{v_1,v_2,v_3\}$ 指定。连接顶点 v_i 和 v_j 的边记为 e_{ij}。

P | 由 n_P 个离散点组成的集合 {p_i∈ℝ³}_{i=1}^{n_P}，表示对潜在表面 S* 的实际采样。

n_p | 在表面点 p 处定义的、估计得到的定向表面法向；n_p∈ℝ³。

N(p) | 以点 p 为中心的局部点邻域。

Ω | 某个子空间的定义域，例如 $\Omega^k \subset \mathbb{R}^k$。

C^k | 函数的光滑性，其中 k 是函数在某个定义域上具有连续导数的阶数。

d(p) | 点 p 处的有符号或无符号距离场值。

f_θ 或 F_θ | 由参数 θ 参数化的显式或隐式表面重建模型，例如神经网络；参数也记为 θ_f 或 θ_F。

$\nabla_x f_\theta$ 或 $\nabla_x F_\theta$ | 模型关于 x 的导数。

L(S; P) | 用于衡量重建表面 S 与观测点集 P 之间数据保真性的损失函数。

R(S) | 施加在重建表面 S 上的正则项。

K | 相机的外参矩阵。

III. 按几何先验分类的表面重建方法

给定观测点集 P，重建表面 S 在某种距离度量下应接近 P；抽象目标式（1）中的第一个数据保真项 L(S; P) 保证这一点。第 II 节还说明，L(S; P) 可以采用显式或隐式形式具体化。显式形式的一个例子可写为：

$$L^{\exp}(\boldsymbol{f};\mathcal{P}) = \frac{1}{n_{\mathcal{P}}}\sum_{\boldsymbol{p}\in\mathcal{P}}\min_{\boldsymbol{x}\in\Omega^2}\|\boldsymbol{f}(\boldsymbol{x})-\boldsymbol{p}\|_{\ell}, \qquad (5)$$

其中，‖·‖_ℓ 表示适当的距离范数，ℓ 通常取 1 或 2；上述式（5）约束映射函数 f∈H_f 的学习。在实践中，可以采样固定的一组 {x∈Ω²}，而非在整个定义域 Ω² 上优化，从而得到基于点集距离的式（5）的不同变体，例如 Chamfer 距离或 Hausdorff 距离。L(S; P) 的隐式形式的一个例子可写为：

$$L^{\mathrm{imp}}(F;\mathcal{P}) = \frac{1}{n_{\mathcal{P}}}\sum_{\boldsymbol{p}\in\mathcal{P}}\|F(\boldsymbol{p})\|_{\ell}, \qquad (6)$$

这一形式通过最小化任意 p∈P 处 F(p) 的适当范数，学习隐式函数 F∈H_F。隐式数据保真损失还有更复杂的版本，例如：

$$\begin{aligned} L^{\mathrm{imp++}}(F;\mathcal{P}) &= \alpha_1\mathbb{E}_{\boldsymbol{q}\in\mathbb{R}^3}\|F(\boldsymbol{q})-d(\boldsymbol{q};\mathcal{P})\|_{\ell_1} \\ &+ \alpha_2\mathbb{E}_{\boldsymbol{q}\in\mathbb{R}^3}\|\nabla_{\boldsymbol{q}}F(\boldsymbol{q})-\boldsymbol{n}(\boldsymbol{q};\mathcal{P})\|_{\ell_2}+\cdots, \qquad (7)\end{aligned}$$

其中，当 F 表示有符号距离函数（Signed Distance Function，SDF）[8]、[33]、[34] 时，d(q; P) 表示任意空间点 q∈ℝ³ 与观测点集 P 之间的有符号距离；当 q 落在某个 p∈P 上时，该距离为零。当 F 表示占据场（Occupancy Field，OF）[9]、[35]、[36] 时，d(q; P)∈{0,1}，取值取决于 q 位于表面 S 的内部还是外部，实际中通过比较 q 与观测点集 P 来估计。n(q; P) 表示点 q 处的法向；当 q 落在某个 p∈P 上时，可通过计算 P 在 p 处的局部切平面来估计它，否则满足 ‖n(q; P)‖₂=1。当 F 表示 SDF [37] 时，式（7）中的第二项相应写为 E_{q∈ℝ³}|‖∇_qF(q)‖₂-1|。文献 [37]、[38]、[39] 可使用 {α₁,α₂,...}，对式（7）中的不同项加权，或将它们启用 / 停用。

由于从 P 进行表面重建具有不适定性，数据保真损失项（5）或（6）都不足以重建几何上合理的 S。已有文献提出了式（1）中正则化项 R(S) 的各种具体形式，以使问题具有更好的适定性。

[1] 写出式（1）这一简化形式时，我们省略了某些可以从观测点集 P 计算出的信息的符号，例如与各点 p∈P 对应的表面法向；我们也省略了某些有助于表面重建、但需要额外提供的信息，例如采集 P 时扫描器的位姿。给定额外提供的相机位姿，可以将式（1）改写为：

$$\min_{\mathcal{S}} L(\mathcal{S};\mathcal{P},\boldsymbol{K}) + \lambda R(\mathcal{S}), \qquad (2)$$

其中，K 表示相机的外参矩阵。式（2）有助于表面重建，因为可以使用给定的 K 来确定表面法向的朝向，详见第 VI-C 节。

原文 PDF 第 6 页 · 期刊页 9732

在本节余下部分，我们按照现有表面重建方法所采用的几何先验正则化方式进行分类，讨论这些方法的本质。这些先验包括三角剖分先验、平滑性先验、模板先验、建模先验、学习先验和混合先验；分类同时涵盖经典方法与近期的深度学习方法。我们期望，这种分类与讨论能够连接经典表面重建方法与较新的深度学习方案，推动新的创新。

A. 三角剖分先验

闭合表面是连续的，并且在局部可以具有不同阶的可微性。当需要由 P 恢复的 S 在局部一阶可微，即 f 在局部属于 C^1 时，分段线性假设是建模该表面的良好先验，可由此得到表面的网格表示。在各种网格划分方案中，Delaunay 三角剖分 [40] 是一种经典方法，它将 S 近似为满足特定空球性质的网格，可写为：

$$\begin{aligned}
&\mathcal{G}_{\mathcal{S}} = \{\mathcal{T}_i\}_{i=1}^{n_G} \\
&\text{s.t.} \quad \boldsymbol{v}_1^{\mathcal{T}} \in \mathcal{P}, \boldsymbol{v}_2^{\mathcal{T}} \in \mathcal{P}, \boldsymbol{v}_3^{\mathcal{T}} \in \mathcal{P} \; \forall \, \mathcal{T} \in \mathcal{G}_{\mathcal{S}}, \\
&\left(\boldsymbol{p} \notin \mathrm{CC}(\mathcal{T}) \; \forall \, \boldsymbol{p} \in \mathcal{P} / \{\boldsymbol{v}_1^{\mathcal{T}}, \boldsymbol{v}_2^{\mathcal{T}}, \boldsymbol{v}_3^{\mathcal{T}}\}\right) \; \forall \, \mathcal{T} \in \mathcal{G}_{\mathcal{S}}, \qquad (8)
\end{aligned}$$

其中，T 为三角面，其三个顶点记为 $\{v_1^T, v_2^T, v_3^T\}$；n_G 为面数；CC(T) 表示经过 T 的三个顶点的外接球所包围的空间。请注意，Delaunay 三角剖分同时满足显式数据保真性条件 (5)。我们还指出，虽然 Delaunay 三角剖分能够灵活地适应复杂形状，但它在三维空间中并没有良好的定义。大多数重建方法将其用作初始化 [41] 或正则化 [42]，或者扩展 Delaunay 四面体剖分，以在重建中去除形状不理想的三角形 [6]。

采用 Delaunay 三角剖分的代表性方法 [41]、[42]，首先直接从观测点集 P 生成一组三角面，再从中选出最优子集，形成最终的三角网格。Greedy Delaunay（GD）[41] 提出一种基于拓扑约束的贪心算法，依次选择有效三角形，其初始三角形由 Delaunay 三角剖分生成。Ball-Pivoting Algorithm（BPA）[42] 使用不同半径的球在 P 中的点上滚动，生成三角形：滚动球接触的每三个点，只要由它们形成的三角形不包含任何其他点，就构成一个新三角形；这也可以视为 Delaunay 三角剖分的一种近似。

B. 表面平滑性先验

在更一般的情形中，通常期望需要恢复的表面 S 是平滑的，或者具有某一阶的连续可微性 [32]。表面平滑性通常通过下述策略实现。

通过局部加权组合实现表面平滑性——第一种策略在拟合显式映射函数 f 时，以局部加权组合对 {p ∈ P} 进行平滑。例如，文献 [43] 中的平滑性先验是式 (5) 的正则化形式：

$$\begin{aligned}
\min_{\boldsymbol{f}} L^{\exp}(\boldsymbol{f}; \mathcal{P}) &= \frac{1}{n_{\mathcal{P}}} \sum_{\boldsymbol{p} \in \mathcal{P}} \min_{\boldsymbol{x} \in \Omega^2} \|\boldsymbol{f}(\boldsymbol{x}) - \hat{\boldsymbol{p}}(\boldsymbol{p})\|_2^2 \\
\text{s.t. } \hat{\boldsymbol{p}}(\boldsymbol{p}) &= \sum_{\boldsymbol{p}' \in \mathcal{N}(\boldsymbol{p})} \boldsymbol{p}' g(\|\boldsymbol{p} - \boldsymbol{p}'\|_2), \qquad (9)
\end{aligned}$$

其中，N(p) 表示观测点 p 的局部邻域，包含点 {p′ ∈ P}；$g(\|p - p'\|_2)$ 为归一化权重函数，例如归一化径向基函数（Radial Basis Function，RBF），其值随距离 $\|p - p'\|_2$ 的增大而减小。在 Poisson Surface Reconstruction（PSR）[38] 中，通过对式 (7) 的二阶项进行正则化，采用了类似的隐式目标：

$$\min_F L^{\mathrm{PSR}}(F;\mathcal{P}) = \mathbb{E}_{\boldsymbol{q}\in\mathbb{R}^3}\|\nabla_{\boldsymbol{q}}F(\boldsymbol{q}) - \hat{\boldsymbol{n}}(\boldsymbol{q};\mathcal{P})\|_2^2$$

$$\text{s.t. } \hat{\boldsymbol{n}}(\boldsymbol{q};\mathcal{P}) = \sum_{\boldsymbol{p}'\in\mathcal{N}(\boldsymbol{q})} \boldsymbol{n}(\boldsymbol{p}';\mathcal{P})g(\|\boldsymbol{q}-\boldsymbol{p}'\|_2), \qquad (10)$$

其中，N(q) 表示空间点 q ∈ ℝ³ 的局部邻域，包含观测点 {p′ ∈ P}。PSR 仅约束法向场，因此通常会产生过度平滑的结果。作为补救，Screened Poisson Surface Reconstruction（SPSR）[39] 在 PSR 的基础上，同时纳入式 (7) 中一阶项与二阶项的正则化形式。近期，Shape As Points [44] 以谱方法构建了可微 Poisson 求解器，使端到端优化成为可能，因而能够集成到深度神经网络的学习过程中。

通过约束函数复杂度实现表面平滑性——这也可以等价地通过约束 H_f 或 H_F 的假设空间实现，例如将 H_f 限制为 B 样条函数 [45]、[46]、[47]、NURBS [48]、[49] 或高斯函数 [50]、[51]、[52]。直观地说，复杂度更高的函数能够拟合几何形状复杂的表面，但也更容易对观测点集 P 过拟合，生成平滑性较差的表面。例如，文献 [53] 使用 RBF，意味着近似函数采用低阶多项式形式，并对许多以观测点为中心的基函数进行插值。文献 [54]、[55] 与 [53] 类似，但使用不同基函数近似各自的隐式场函数。具体而言，Kazhdan [54] 首先借助散度定理的 Monte Carlo 近似计算其隐式场函数的 Fourier 系数，再利用 Fourier 逆变换获得用于提取等值面的隐式函数。文献 [54] 需要规则网格来执行快速 Fourier 变换，而 Manson 等 [55] 改用小波，为隐式函数提供局部化、多分辨率表示。文献 [50] 不采用规则网格，而是在若干拓扑约束下，通过求解高斯基函数参数，在更精细的网格上优化似然函数。近期，He 等 [56] 提出在表面重建时对网格曲率进行正则化，从而得到更平滑的重建表面。Wang [51] 在能量项中引入高斯卷积，在迭代优化过程中促进所学习隐式函数的平滑性。

原文 PDF 第 7 页 · 期刊页 9733

PGR [52] 选择由高斯形式引导的示性函数基函数，从未定向点集恢复表面。

通过组合策略实现表面平滑性——Point Set Surfaces（PSS）[43]、[57]、[58]、[59] 等方法结合了上述两种平滑策略。PSS 源于 Moving Least Squares（MLS）[60]、[61]、[62]、[63]，其表面既可以由具有稳态投影算子的显式函数定义 [43]、[57]、[58]、[60]、[61]，也可以由隐式函数定义 [59]、[62]、[63]。无论采用哪种方式，对随空间变化的低阶多项式进行加权组合，都是局部近似观测点并构造表面的最关键组成部分。在 Simple Point Set Surfaces（SPSS）[58] 中，作者迭代地沿法向方向，将所有给定点投影到局部参考平面上；这些平面由待投影点及其邻域点的加权平均定义。随后，每个求值点处的局部参考平面提供一个局部正交坐标系，以计算表面的局部二元多项式近似。然而，当观测点稀疏时，局部参考平面很难成为良好近似，有时甚至会不稳定。Algebraic PSS [59] 通过使用代数球拟合观测点来克服这一问题，并形成一个隐式函数，表示求值点与拟合球之间的代数距离。随后，通过代数球梯度场与观测点法向之间的最小二乘问题求解拟合。Robust Implicit MLS（RIMLS）[63] 将核回归和统计鲁棒性与 MLS 结合，应对 MLS 只能重建平滑表面的局限。其他 PSS 方法遵循相同原理；更多细节可见文献 [64] 和 [3]。

C. 模板先验

模板先验假设表面可以由一组模板的组合表示，其中模板既可以是球、立方体等几何基元，也可以是来自辅助数据集的复杂模板。这样，表面重建就归结为估计正确模板并将其拟合到观测点集 P 的问题。其一种数学定义方式为：

$$\min_{\{w\},\{\boldsymbol{\theta}\}} D\left(\sum_{i=1}^{|\{\mathcal{M}\}|} w_i \mathcal{M}_i(\boldsymbol{\theta}_i), \mathcal{P}\right), \qquad (11)$$

其中，{M} 表示预定义模板集合；每个模板 M 由 θ 参数化，θ 可能是可学习的，并以 w 加权；D(·, ·) 表示所形成表面与 P 之间的适当距离。通过最小化拟合误差 (11)，可以由确定的 {w} 和/或 {θ} 重建表面。

1）几何基元

几何基元模板是能够用一定数量的参数解析表示的简单形状，例如长方体、球、圆柱、圆锥等。Random Sample Consensus（RANSAC）[65]、[66] 是求解式 (11)、将正确模板拟合到观测点集 P 的最常用方法。其中，D(·, ·) 对随机采样点 {p ∈ P} 与它们在拟合模板上的投影之间的逐点欧氏距离求和。具体而言，Schnabel 等 [65] 引入了高效的 RANSAC 算法，采用新的采样策略与高效的评分方案，迭代提取得分最高的基元。Nan 和 Wonka [66] 提出仅基于 RANSAC 提取平面基元，再最小化若干能量项的加权和以选择最优面集合，获得最终表面。Zhu 等 [67] 则用由偏微分方程解定义的不同基元补丁，拟合分割后的点云，从而重建表面。

2）基于检索的模板

给定形状模型的辅助集合 {M}，检索与变形方法通过求解式 (11)，找到最接近的形状，并优化模型参数 {θ} 对其进行变形，以拟合观测点集 P。例如，在场景重建 [68]、[69]、[70]、[71] 中，观测场景点首先被划分为不同语义类别，再用检索到的形状模型拟合各类点，并进行刚性或非刚性变形。在对象重建中，Pauly 等 [72] 对检索到的多个对象形状进行扭曲与融合，使其符合观测点；Shen 等 [73] 则检索单独的对象部件，通过部件装配形成表面。

D. 建模先验

如第 III-B 节所述，约束 H_f 或 H_F 假设空间的复杂度，有助于重建更平滑的表面；而对 H_f 或 H_F 本身的选择也会对重建产生正则化作用，因为这一选择只能建模特定类型的表面。一个突出的例子，是近期使用深度神经网络进行几何建模与表面重建的趋势。我们将不同模型设计自身提供的几何先验称为建模先验。

受到 Deep Image Prior [74] 的启发，Deep Geometric Prior（DGP）[75] 验证了深度网络作为几何表面建模先验的有效性，即使这些网络没有经过训练也仍然有效。此后，Point2Mesh [76] 和 SAIL-S3 [77] 将文献 [75] 采用的全局建模扩展为局部建模：前者将局部隐式函数构造为权重共享的 MeshCNN [78]，后者则将其构造为权重共享的多层感知机（Multi-Layer Perceptron，MLP）。Deep Manifold Prior [79] 对 MLP 与卷积网络的这种建模性质进行了数学分析。还有一些工作使用了建模先验，却没有明确提及这一概念。Atzmon 等 [80] 从理论上证明，采用整流线性单元（Rectified Linear Unit，ReLU）的 MLP 能够生成分段线性表面；文献 [81] 还提出了 Analytic Marching 网格生成算法，能够从此类网络中解析计算分段线性表面网格。这两项工作都从数学上分析了 MLP 的结构自身如何发挥正则化作用。随后，Deep Manifold Prior [79] 将这种建模性质扩展到 MLP 和卷积网络。Implicit Geometric Regularization（IGR）[37] 表明，对神经网络梯度施加额外正则化，可以进一步促进所生成表面的平滑性。

Sign Agnostic Learning（SAL）[82] 及其变体 [83]、[84] 研究通过经过专门初始化的神经网络，从未定向点云重建表面。SSP [85] 进一步利用对未定向输入点进行体素化而生成的半符号监督，以避免陷入不良局部极小值；Davies 等 [86] 采用相同的初始化策略，从具有定向法向的点云重建表面。Neural Splines [87] 基于无限宽浅层 ReLU 网络产生的随机特征核进行重建，并表明此类解倾向于重建平滑表面。

E. 学习先验

设 f ∈ H_f 的参数为 θ_f，F ∈ H_F 的参数为 θ_F，先验可以通过在辅助训练形状集合上学习而得到，表现为经过优化的模型参数。请注意，这种学习先验不同于上一节的建模先验，后者的先验由模型本身提供。设 $\{\mathcal{P}_i, \mathcal{S}_i^*\}_{i=1}^N$ 为训练集，包含 N 对观测点集及其对应的真实表面。通过调整目标函数 (3)，文献 [5]、[88] 提出了以下基于学习先验的显式表面重建形式：

$$\min_{\boldsymbol{z}} L^{\exp}\left(\boldsymbol{f}(\boldsymbol{z};\tilde{\boldsymbol{\theta}}_{\boldsymbol{f}});\mathcal{P}\right)+\lambda R^{\exp}(\boldsymbol{z}) \tag{12}$$

$$\text{s.t. } \tilde{\boldsymbol{\theta}}_{\boldsymbol{f}} = \arg\min_{\boldsymbol{\theta}_{\boldsymbol{f}}} \frac{1}{N}\sum_{i=1}^{N} \tilde{L}^{\exp}\left(\boldsymbol{\theta}_{\boldsymbol{f}};\{\mathcal{P}_i,\mathcal{S}_i^*\}\right)+\tilde{\lambda}\tilde{R}^{\exp}(\boldsymbol{\theta}_{\boldsymbol{f}}), \tag{13}$$

其中，约束 (13) 以优化后的模型参数 θ_f 的形式学习先验；L̃_exp 可以不同于 L_exp；除对 θ_f 施加简单的范数约束外，还可以在 R̃_exp 中加入使表面平滑和/或光顺的目标。给定已学习并固定的 θ_f，目标函数 (12) 通过优化潜在编码 z，将模型预测拟合到任意观测点集 P；通常对 z 的范数施加惩罚，以防止过拟合。类似地，通过调整目标函数 (4)，下述方法 [8]、[9] 为隐式表面重建学习先验：

$$\min_{\boldsymbol{z}} L^{\text{imp}}\left(F(\boldsymbol{z};\tilde{\boldsymbol{\theta}}_F);\mathcal{P}\right)+\lambda R^{\text{imp}}(\boldsymbol{z}) \tag{14}$$

$$\text{s.t. } \tilde{\boldsymbol{\theta}}_F = \arg\min_{\boldsymbol{\theta}_F} \frac{1}{N}\sum_{i=1}^{N} \tilde{L}^{\text{imp}}\left(\boldsymbol{\theta}_F;\{\mathcal{P}_i,\mathcal{S}_i^*\}\right)+\tilde{\lambda}\tilde{R}^{\text{imp}}(\boldsymbol{\theta}_F). \tag{15}$$

模型 f 还可以构造为自动编码器架构 [9]、[35]、[89]，即 f = f_encoder ∘ f_decoder。在这种情况下，给定由式 (13) 学到的先验 θ_f = {θ_f_encoder, θ_f_decoder}，可以直接得到潜在编码：

$$\boldsymbol{z} = \boldsymbol{f}_{\text{encoder}}\left(\mathcal{P};\tilde{\boldsymbol{\theta}}_{\boldsymbol{f}_{\text{encoder}}}\right), \tag{16}$$

而不必优化目标函数 (12)。上述方式同样适用于基于自动编码器的隐式函数 F = F_encoder ∘ F_decoder。给定已学习的先验 θ_F = {θ_F_encoder, θ_F_decoder}，可以直接计算其潜在编码：

$$\boldsymbol{z} = F_{\text{encoder}}\left(\mathcal{P};\tilde{\boldsymbol{\theta}}_{F_{\text{encoder}}}\right). \tag{17}$$

请注意，最新的隐式方法 [36]、[90] 允许在拟合观测点时进一步优化模型参数先验，即在式 (12) 或 (14) 中同时优化潜在编码与模型参数，因而有望连接学习先验与经典先验。

根据训练形状集合 $\{P_i, S_i^*\}_{i=1}^N$ 的组织方式，通过式 (13) 或 (15) 学到的先验，既可以处于全局语义层面，也可以表现为局部形状基元。例如，当 $\{P_i, S_i^*\}_{i=1}^N$ 中的样本对描述同一语义类别下对象实例的表面时，学习到的先验就会编码该对象类别共有的形状模式。为了学习用于任意表面形状重建的先验，可能需要将 $\{P_i, S_i^*\}_{i=1}^N$ 准备为编码表面补丁的数据，并期望通过为局部形状基元提供先验，更好地重建具有任意形状的全局表面。

1) 学习语义先验

近期基于深度学习的表面重建趋势始于在语义层面学习深度先验，例如针对某一类别的对象实例学习先验。举例而言，显式方法 Deep Marching Cubes [88] 提出了新的可微 Marching Cubes 层，通过生成位移体素网格的形状编码网络，将网格表面生成与语义先验学习连接起来。开创性的深度学习隐式方法 [8]、[9]、[91] 通过深度神经网络建模有符号距离场 SDF 或占据函数 OF。具体而言，OccNet [9] 与 IM-Net [91] 采用自动编码器结构：训练后，对于任意观测点集，编码器通过式 (17) 中的一次前向传播生成表示形状的潜在编码，解码器则根据给定空间点及潜在编码预测占据概率。与 OccNet 和 IM-Net 不同，DeepSDF [8] 采用仅包含解码器的模型结构，通过式 (14) 中的最大后验估计优化给定点云的潜在编码，并根据给定空间点及潜在编码预测有符号距离。Curriculum DeepSDF [92] 在 DeepSDF 的基础上引入渐进学习策略，以学习局部细节；与此同时，Yao 等 [93] 使用图神经网络实现这种学习，在将编码送入解码器前，把全局语义潜在编码转化为更复杂的局部编码。MeshUDF [94] 进一步扩展 DeepSDF，使其能够重建开放表面：它预测任意给定空间点的无符号距离，并使用专门设计的 Marching Cubes 方法生成表面。近期，一些方法 [95]、[96] 采用基于 Transformer [97]、[98] 的网络辅助重建。还应注意，学习语义先验可以通过训练编码器，使其从原始观测中学习潜在形状空间，从而能够由本身不含或只含较少三维形状信息的原始观测重建表面，例如仅用单张 RGB 图像 [5]、[99]、[100]。

2) 将局部形状基元作为先验进行学习

为了重建场景表面，或者无法归入特定语义类别的对象表面，现有方法采用建模与学习局部形状基元先验的方式：这些先验要么位于划分三维空间的规则网格上 [10]、[34]、[35]、[101]、[102]、[103]、[104]，要么位于沿表面流形分布的局部补丁上 [33]、[89]、[105]。

在前一类方法中，Implicit Feature Networks（IF-Net）[101] 和 Convolutional OccNet [35]（ConvOccNet）通过自动编码器结构获得局部网格的潜在编码。其中，IF-Net [101] 采用三维卷积，将每个输入点与其周围的点进行卷积，以获得各局部网格的潜在编码；ConvOccNet [35] 则采用 PointNet [106] 作为编码器，获得每个点的潜在编码，再通过平均池化将所有潜在编码汇集为体积特征。随后，Chibane 等 [102] 将 IF-Net [101] 扩展为支持不依赖符号的学习。Deep Local Shape（DeepLS）[34] 将整个三维空间划分为规则体素，并训练一个隐式函数，使不同局部体素共享该函数的参数。Local Implicit Grid（LIG）[10] 在训练阶段训练自动编码器，提取局部体素的潜在编码（通过式 (17)）；在推理阶段，则仅保留参数固定、由体素共享的解码器。为提高局部编码的效率，Scalable Surface Reconstruction Network（SSRNet）[103] 利用八叉树划分整个三维空间，并采用带跳跃连接的全卷积 U 形网络。该网络基于经过修改的切向卷积 [107]，获得各局部网格的潜在编码。Neural Geometric Level of Detail（LOD）[104] 采用稀疏八叉树结构进一步提高效率，仅对与表面相交的局部体素计算潜在编码。Ummenhofer 等 [108] 在八叉树输入空间的多个层级上使用自适应网格卷积，聚合局部网格的潜在编码。对于基于局部表面补丁的方法，Badki 等 [105] 引入了 meshlet 的概念，并训练变分自动编码器，学习姿态解耦的 meshlet 潜在空间；在推理时，该方法通过反向传播给定点与 meshlet 之间的误差，更新 meshlet 的潜在编码，并使 meshlet 变形以拟合给定点。PatchNets [33] 利用隐式自动解码器结构，在不同的局部表面补丁之间学习；同时，采用精心设计的损失函数训练解码器，以确保重建补丁的平滑性。Points2Surf [89] 同时学习局部补丁和全局表面的特征，并利用隐式解码器重建表面：前者使用局部编码器学习查询点到局部表面的绝对距离，后者则使用全局编码器学习表面的内外关系。POCO [109] 和文献 [110] 将每个输入点编码为单个潜在编码，再在一个点及其相邻点之间进行加权插值，获得局部潜在编码。Ma 等 [111] 训练局部上下文网络，将局部区域内的点编码为潜在编码，然后利用以这些编码为条件的 SDF 解码这些区域中的查询点。测试时，还要优化另一个查询网络，以预测全局区域对应的局部查询点和条件编码；随后将它们输入局部上下文网络的解码器，获得表面的 SDF。

F. 混合先验

前面各节按照方法使用的主要表面几何先验，对其进行了组织分类。为提高重建表面的合理性，现有方法通常结合多种先验，例如，将平滑性先验与三角剖分先验或模板先验相结合 [112]、[113]、[114]；在建模先验的基础上施加额外先验 [115]、[116]、[117]、[118]、[119]、[120]、[121]、[122]；或通过学习先验，改进预定义先验提供的正则化效果 [6]、[7]、[47]、[123]、[124]、[125]。考虑到最后一种混合先验在深度学习表面重建的新时期得到了广泛应用，本节重点讨论这种情形。

给定辅助训练形状集合，文献 [7]、[123]、[126] 将学习先验与三角剖分先验相结合，促使深度网络从观测点云中学习三角剖分所需的特定性质。具体而言，PointTriNet [7] 提出了一个直接由观测点云生成三角形的框架：提议网络提出候选三角形，分类网络预测某个候选三角形是否应出现在重建表面上；两个网络迭代发挥作用，直到生成最终的三角网格表面。Liu 等 [126] 表明，连接测地距离接近欧氏距离的顶点对，可以近似重建底层表面；他们构建了一个网络，选择满足该性质的候选三角形。Delaunay Surface Elements（DSE）[123] 将 Delaunay 三角剖分与学习得到的对数映射结合，生成小型三角剖分补丁；随后，通过其提出的自适应投票算法，从这些补丁中迭代选择输出表面的候选三角形。DeepDT [6] 学习深度网络，从观测点云中提取几何特征，再将学习到的特征与图结构信息结合，通过投票确定 Delaunay 四面体的内部或外部标签；通过提取具有不同标签的四面体之间的三角面，重建表面。Gao 等 [127] 学习一个网络来预测四面体顶点的偏移量，并学习第二个网络来预测各四面体的占据状态；在占据状态不同的两个四面体共有的面上生成对象表面。

学习先验也常与平滑性先验相结合，例如，文献 [128] 中的拉普拉斯正则化和文献 [129] 中的余弦平滑性。IMLSNet [124] 训练隐式网络，在基于八叉树的三维空间网格上计算有符号距离；它以类似隐式移动最小二乘

法 [63] 的方式定义有符号距离，从而施加平滑性正则化。Xiao 等 [130] 学习一个网络，对由高斯引理推导出的示性函数进行隐式建模；该函数是平滑的，并以线性方式近似表面。与 Points2Surf [89] 类似，他们同时学习局部和全局特征。

还有大量工作 [47]、[125]、[131]、[132] 将学习先验与模板先验结合。SPFN [125] 提出训练深度网络，根据观测点云拟合几何基元；训练后的网络预测逐点特征，再将这些特征输入可微估计器，通过代数计算获得基元参数。CPFN [131] 学习两个 SPFN：全局网络用于检测较大的基元，局部网络用于捕获较小的基元。

原文 PDF 第 10 页 · 期刊页 9736

表 2

Surface complexity	Low	Middle	High	Total
Thingi10k [22]	516	230	97	845
3DNet Cat200 subset [20]	144	89	33	266
ABC [21]	312	160	6	478
Three D Scans [23]	0	7	26	31
Our benchmark	972	486	162	1,620

表 II：基准从现有数据仓库收集的合成对象实例，以及这些实例在低、中、高复杂度三个组中的分布。字段含义：Surface complexity 为表面复杂度；Low、Middle、High 分别为低、中、高复杂度；Total 为总数。数据来源包括 Thingi10k [22]、3DNet Cat200 subset [20]、ABC [21] 和 Three D Scans [23]；Our benchmark 表示本文基准。

ParseNet [47] 使用神经分解模块，将观测点云划分为多个子集；假定每个子集属于一种基元类型，并由深度网络将其建模为开放或闭合 B 样条。Local Deep Implicit Function（LDIF）[132] 将表面形状表示为一组形状元素，每个元素都由解析形状变量和潜在形状编码参数化；该方法分别通过 SIF 编码器和 PointNet 编码器学习这些变量与潜在编码。对于大规模场景表面重建，RetrievalFuse [133] 从辅助场景数据集中检索一组对象模板，并学习一个具有注意力细化机制的网络，以生成重建结果。

IV. 表面重建基准

如第三节所述，已有丰富的方法用于解决由点观测重建表面的不适定问题。这些方法各有优点，但由于缺少一个能够识别并涵盖该问题主要挑战的综合表面重建基准，它们在不同工作条件下的优势与劣势仍不够清楚。

在本工作中，我们通过合成点云和实际扫描对象及场景表面的点云，构建了这样的基准。我们明确了由不完善的表面扫描得到点云时，表面重建面临的主要挑战，包括逐点噪声、点离群值、点分布不均匀、扫描对象或场景中不同但相互重叠的局部表面时所得点集之间的配准错位，以及一个或多个表面补丁中的点缺失。图 1 展示了这些挑战。我们在基准的合成数据中纳入全部五种挑战，并认为它们的任意组合都可能出现在真实扫描数据的任意样本中。该基准分为对象表面合成数据、场景表面合成数据和真实扫描表面数据。表 III 和表 IV 汇总了其统计信息。我们在 https://Gorilla-Lab-SCUT.github.io/SurfaceReconstructionBenchmark 公开提供该基准，同时发布合成扫描流程的代码实现，以促进社区未来的研究。

表 3

		Object level		Scene level
normalization $[r_{\min}, r_{\max}]$ (camera distancing)		centering+scaling [2.5, 3.5]		centering [0.75m, 2.1m]
point-wise noise	σ_{noise}	0.001/0.003/0.006		0.005m
point outliers	$[a_{\text{outlier}}, b_{\text{outlier}}]$ r_{outlier}	[0.01, 0.1] 0.1%/0.3%/0.6%		[0.01m, 0.1m] 0.4%
missing points	φ $\Delta\varphi$	[20°, 40°, 60°]/[20°, 40°]/[20°] 3°		-
misalignment	$[a_{\text{rotation}}, b_{\text{rotation}}]$ $[a_{\text{translation}}, b_{\text{translation}}]$	[−0.5°, 0.5°]/[−1°, 1°]/[−2°,2°] [−0.005, 0.005]/[−0.01, 0.01]/[−0.02, 0.02]		[−1.5°, 1.5°] [−0.015m, 0.015m]
#viewpoints		1000		$100/\text{m}^3$
#scanned points		low complexity middle complexity high complexity	80k 120k 160k	1000k
#surfaces		1620		50

Elements in each triple · / · / · represent the hyper-parameters that control the scanning with three levels of severity; # denotes the number. (cf. Sections 4.1 and 4.2 for specific meanings of the math notations.)

表 III：基准中合成数据的统计。Object level 和 Scene level 分别表示对象级和场景级数据；normalization 表示归一化方式，其中 centering 为居中，centering + scaling 为居中并缩放；[r_min, r_max]（camera distancing）为相机距离范围；point-wise noise 及 σ_noise 为逐点噪声及其参数；point outliers 下的 [a_outlier, b_outlier] 和 r_outlier 为离群点相关参数；missing points 下的 φ 和 Δφ 为缺失点相关参数；misalignment 下的 [a_rotation, b_rotation] 及 [a_translation, b_translation] 分别为旋转和位移配准错位的参数范围。#viewpoints、#scanned points 和 #surfaces 分别表示视点数、扫描点数和表面数；low complexity、middle complexity、high complexity 分别为低、中、高复杂度。每组三元值（· / · / ·）中的元素表示控制三种严重程度扫描的超参数；# 表示数量。数学记号的具体含义见第 4.1 和 4.2 节。

表 4

		Einscan SE	OKIO 5M
precision		100 micrometers	5 micrometers
professional operators		×	✓
#resolution		$1300k$	$5000k$
#viewpoints		30-50	13-35
#scanned points		$210k$-$3000k$	$330k$-$2000k$
#surfaces		20	
#material	metal	4	
	plastic	9	
	ceramic	5	
	cloth	2	

denotes the number.

表 IV：真实扫描数据的统计。两列扫描设备为 Einscan SE 和 OKIO 5M。字段含义：precision 为精度；professional operators 为是否由专业人员操作；#resolution 为分辨率；#viewpoints 为视点数；#scanned points 为扫描点数；#surfaces 为表面数；#material 为不同材料的数量，其中 metal、plastic、ceramic、cloth 分别为金属、塑料、陶瓷和布料。micrometers 为微米，# 表示数量。

A. 对象表面的合成数据

为准备基准中的对象实例合成数据，我们从现有数据仓库 [20]、[21]、[22]、[23] 收集 CAD 模型，并在合成扫描其点云之前进行预处理。对于每个 CAD 模型，除了通过理想扫描得到干净对象点云外，我们还模拟前述五种不完善的扫描情形；因此，每个实例共有六种扫描点云。我们按照（代数）表面复杂度 [134]，将收集到的对象实例分为三个等级，以研究不同方法在重建不同复杂度表面时的表现。

1）数据收集

我们从现有数据仓库 Thingi10k [22]、ABC [21]、3DNet Cat200 subset [20] 和 Three D Scans [23] 收集对象实例的 CAD 模型。具体而言，我们从 Thingi10k [22]（一个由网上分享的三维打印模型组成的数据集）随机选择了 3,000 个对象，从 ABC [21] 的 Chunk 0080 集合中随机选择了 3,000 个工业零件，从 3DNet Cat200 subset [20] 中随机选择了 3,400 件商品，并从 Three D Scans [23] 中随机选择了 106 件艺术雕塑。这些实例均以三角网格形式表示。如图 2 所示，部分收集到的实例网格可能不具备水密性、存在自遮挡，或拓扑结构过于复杂，因此不便通过合成扫描模拟实际传感条件；我们通过判断其水密性及二维流形性质 [135]、检查自遮挡 [136] 和计算表面的亏格 [32]，过滤掉这些实例。最后，对保留下来的各实例网格进行归一化，将其中心置于原点，并进行各向同性缩放，使其容纳于单位球中。我们最终在基准中获得了 1,620 个对象表面网格。

2）不同表面复杂度的分组

不同方法的性能可能取决于待重建对象表面的复杂度。

原文 PDF 第 11 页 · 期刊页 9737

为明确不同方法各自更合适的工作条件，我们拟将上述经过处理的物体表面网格按不同复杂度分组。表面复杂度可以用不同指标衡量，其中代数复杂度和拓扑复杂度与点云表面重建更为相关[134]；简单来说，前者衡量表示表面所需的多项式次数，后者可以用表面的亏格衡量，例如表面上的孔洞数量。由于我们的表面网格实例已经经过处理，满足水密、二维流形以及拓扑较简单的条件（亏格等于或小于5），因此我们依据代数复杂度，将全部1,620个实例分为低、中、高复杂度三组。

表面的代数复杂度通常计算为近似或拟合局部表面片所用多项式函数的最高次数[134]。然而，在近似误差限额固定的情况下，用高次多项式拟合局部表面片通常不稳定[60]，会造成对多项式次数、进而对代数复杂度的不准确预测。我们因此采用另一种策略：固定函数的最高次数，并测量局部表面片的平均近似误差；技术细节见在线附录A。最终，三组分别包含972、486和162个实例，低、中、高复杂度组的比例约为6：3：1。表II汇总了各组的统计信息。

3）合成点云扫描

我们使用Blender Sensor Simulation Toolbox（BlenSor）[137]，对所收集物体实例的表面网格进行合成扫描。本节介绍扫描流程，包括如何实现不同的不完美扫描方式，以模拟实际条件下发生的点云感测。

完美扫描——我们首先以完美扫描为例，完整说明图2所示的虚拟扫描流程。如第IV-A1节所述，我们在模拟器中将表面网格实例归一化，使其位于单位球的中心。扫描某一实例时，我们将虚拟飞行时间（TOF）相机[138]放置在半径从$r_{min} = 2.5$到$r_{max} = 3.5$的观察球面上；任一球面上的视点均可由相机外参$K = [R|t] \in \mathbb{R}^{4\times4}$指定，其中旋转$R \in \mathbb{R}^{4\times3}$和平移$t \in \mathbb{R}^{4\times1}$共同确定相机的位置与姿态。将从视点K扫描得到的点云记为P_k；可将其变换到世界坐标系，表示为$K \circ P_k$，其中$\circ$表示一个算子。[2] 在我们的设置中，从不同半径的球面上采样1,000个视点，得到扫描点云集合$\{K_1 \circ P_{k_1}, \ldots, K_{1000} \circ P_{k_{1000}}\}$，其中每个点云仅覆盖部分表面。随后，将不同的局部点

云配准并融合，覆盖完整表面，得到$\bigcup_{i=1}^{1000} K_i \circ P_{ki}$。对$\bigcup_{i=1}^{1000} K_i \circ P_{ki}$应用最远点采样（FPS）[106]，得到最终均匀分布的扫描点云P；对于低、中、高复杂度表面，P分别包含80,000、120,000和160,000个点。

对于需要表面法向才能进行重建的现有方法，我们按以下方式计算定向表面法向。对于任意点$p \in P$，首先以该点的$k = 40$个最近邻构建局部邻域，并通过PCA计算其未定向法向$\tilde{n}_p$；通过比较p与相机位置，即可简单地确定$\tilde{n}_p$的方向，得到定向法向n_p。

逐点噪声——由于传感器噪声、环境噪声、表面的反射特性以及扫描设备精度不足，实际扫描得到的点云不可避免地带有噪声。在这种情况下，每个扫描点并不精确位于真实表面上，而是以逐点独立的方式偏离表面；为模拟这种噪声，我们对上述完美扫描得到的点添加逐点扰动。具体而言，对于任意表面点q，生成$\Delta q_{noise} \in \mathbb{R}^3$，其各元素的值从高斯分布$\mathcal{N}(0, \sigma^2_{noise})$中随机采样，并截断在$[-2\sigma_{noise}, 2\sigma_{noise}]$内。给定点$p \in P$，噪声扫描得到的对应噪声点为$p = q + \Delta q_{noise}$。在基准中，我们将$\sigma_{noise}$分别设为0.001、0.003和0.006，以模拟逐点噪声的不同严重程度。注意，上述截断是为了防止单个点$\{p \in P\}$偏离表面过远，否则它们就会成为下文将讨论的离群点。

点的非均匀分布——实际扫描常常产生点在表面上非均匀分布的点云。例如，被多次扫描、可能从不同视点扫描的表面片会包含更多点，而较近的扫描位置也会产生更密集的点。为模拟这种现象，我们将完美扫描中最后一步用于促进均匀分布的FPS替换为随机采样（RS），所得P在表面上的局部点密度因此会更加不均匀。

离群点——如上所述，表面点云中的离群点定义为偏离表面很远的点，通常由实际扫描中的脉冲噪声引起。我们按以下方式模拟此类离群点。给定完美扫描得到的点云，首先随机采样其中比例为$r_{outlier}$的点；对于任意位于表面上的采样点q，生成$\Delta q_{outlier} \in \mathbb{R}^3$，其各元素的值从均匀分布$\mathcal{U}[a_{outlier}, b_{outlier}]$中随机采样；随后由$p = q \pm \Delta q_{outlier}$得到对应的离群点$p_{outlier} \in P$。我们将$a_{outlier}$设为0.01，以区分离群点和噪声点；将$b_{outlier}$设为0.1，以防离群点距离过远、与表面的关联过弱。$r_{outlier}$分别设为0.1%、0.3%和0.6%，使每个所得P具有不同数量的离群点。

[2] 注意，相机坐标系中的点$p \in P_k$可以通过齐次方程$[p^{world}; 1]^T = [p; 1]^T K^{-1}$，变换为世界坐标系中的点$p^{world} \in P^{world}_k$；这里我们将$P_k$变换为$P^{world}_k$，并整体记为$P^{world}_k = K \circ P_k$。

原文 PDF 第 12 页 · 期刊页 9738

配准错位——如完美扫描部分所述，扫描视点由相机外参$K = [R|t]$指定；从视点K进行扫描，产生仅覆盖部分表面的点云P_k；完整点云则通过从1,000个视点扫描，再将所得点云配准并融合而得到，表示为$\bigcup_{i=1}^{1000} K_i \circ P_{ki}$。然而，当相机外参不够准确时，就会发生配准错位。为模拟这种错位，对于每个视点K，我们生成扰动$\Delta K = [\Delta R|\Delta t] \in \mathbb{R}^{4\times4}$，其中$\Delta R \in \mathbb{R}^{4\times3}$按照XYZ欧拉角约定[139]得到，即$\Delta R = [R_x(\alpha)R_Y(\beta)R_z(\gamma); 0^T_3]$，α、β和γ从$\mathcal{U}[a_{rotation}, b_{rotation}]$中均匀采样；平移扰动$\Delta t \in \mathbb{R}^{4\times1}$的元素从$\mathcal{U}[a_{translation}, b_{translation}]$中均匀采样。对$\bigcup_{i=1}^{1000} (K_i + \Delta K_i) \circ P_{ki}$应用FPS，得到最终带配准错位的点云P。我们将$[a_{rotation}, b_{rotation}]$分别设为[-0.5°, 0.5°]、[-1°, 1°]和[-2°, 2°]，将$[a_{translation}, b_{translation}]$分别设为[-0.005, 0.005]、[-0.01, 0.01]和[-0.02, 0.02]，分别对应不同严重程度的配准错位。

点缺失——由于表面反射、自遮挡和 / 或对表面的覆盖不足，实际扫描常常产生无法覆盖整个目标物体表面的点云。表面反射取决于光照与表面材质的共同作用，而我们收集的CAD模型并未包含材质。为此，我们在基准中采用以下简单方法模拟表面点缺失。与完美扫描中允许扫描视点K_i位于整个观察球面上不同——图2中的蓝色点展示了这一情况——我们只允许K_i位于有限的一组观察位置，以模拟点缺失。具体而言，我们将观察位置定义在几条窄带轨迹内，其极角为$\varphi \pm \varphi\Delta$，如图2中的黄色点所示。对于不同严重程度，我们将轨迹数量分别设为3、2和1，极角φ分别设为[20°, 40°, 60°]、[20°, 40°]和[20°]，并令$\varphi\Delta = 3°$。对于这些不同严重程度，扫描到的表面区域分别约占整个表面的99%、94%和86%。

B. 场景表面的合成数据

我们采用与第IV-A节类似的流程，对场景级数据进行合成扫描。由于场景表面的尺度更大，实际扫描通常会产生同时包含多种不完美因素的点云，因此我们在单个场景的合成扫描中纳入全部五种挑战：逐点噪声、离群点、点的非均匀分布、配准错位和点缺失。图3给出了示意图。

数据收集——我们选择在基准中收集室内场景的CAD表面模型。为建立这一数据集合，我们从SceneNet[24]随机选择28个室内场景，从3D-FRONT[25]选择14个，从Replica[29]选择8个。这三个数据集中的场景在房间类型、房间大小以及所包含的家具和陈设方面具有多样性。收集的表面同样采用三角网格表示。我们将每个场景网格的中心移至原点进行归一化，但保留其原始尺寸。

合成扫描——我们仍使用BlenSor[137]执行场景级合成扫描。在实际室内场景扫描中，扫描仪通常与场景表面保持中等距离；因此，我们选择工作距离为0.75 m至2.1 m的Kinect V2传感器[140]。为准备扫描，将每个室内场景的表面网格放置在一个有界三维空间中，场景中心已经与原点对齐，空间大小设为刚好包围场景表面，参见图3。首先，将三维空间划分为体积为1 m^3、重叠体积为0.5 m^3的立方体；其中一些立方体为空，另一些则包含场景表面的某些局部片。我们选择空立方体的中心作为虚拟相机观察场景的位置，并舍弃其他位置，以确保相机与场景表面之间的工作距离满足上述Kinect V2要求。从每个位置出发，相机都可朝向以该立方体中心为球心的观察球面上的任意方向，观察场景表面的某一局部片。更具体而言，对于位置为$x \in \mathbb{R}^3$的空立方体中心，将其写为齐次形式$t_i = [x; 1] \in \mathbb{R}^4$，随机采样100个方向，得到相机外参$\{K_{ij} = [R_j | t_i]\}_{j=1}^{100}$，其中每个外参都用于生成覆盖场景某一表面片的点云$P_{kij}$。与物体扫描类似，将上述扫描得到的全部点云$\{K_{ij} \circ P_{kij}\}_{i,j}$配准并融合，得到最终点云P。注意，我们没有像物体级合成扫描那样执行FPS；因此，点的非均匀分布这一挑战自然会在这里出现。由于部分方法需要表面法向，我们按与物体扫描相同的方式，计算所有点$p \in P$的定向法向n_p。除自然出现的非均匀分布和由自遮挡造成的点缺失外，我们还按照第IV-A3节所述的相同方式模拟逐点噪声、离群点和配准错位。具体而言，依照Kinect V2相机的设置，将σ_{noise}设为0.005 m以控制逐点噪声水平；将$a_{outlier}$设为0.01 m、$b_{outlier}$设为0.1 m、$r_{outlier}$设为0.4%以控制离群点水平；将$[a_{rotation}, b_{rotation}]$设为[-1.5°, 1.5°]、$[a_{translation}, b_{translation}]$设为[-0.015 m, 0.015 m]以控制配准错位水平。这样的点云P约包含100万个点，并同时包含全部五种挑战。

C. 真实扫描数据

我们使用两台精度不同的深度相机扫描真实物体实例，为基准提供真实扫描数据。扫描物体时，使用精度为100 μm的SHINING 3D Einscan SE[3]获取输入点云，使用精度为5 μm的SHINING 3D OKIO 5 M[4]获取近似真值。[5]

[3] https://www.einscan.com/desktop-3d-scanners/einscan-se/

[4] https://www.shining3d.com/solutions/optimscan-5m

[5] 我们的表面重建评估基于点集距离指标，参见第V-C节。对于这些指标，通过对相应表面网格采样来获取真值点云。因此，我们选择直接使用SHINING 3D OKIO 5 M扫描得到的原始点云，而不使用其内置软件将扫描点云转换为表面网格。



图6. 真实扫描物体数据对的示例。

数据收集——我们收集了20个表面复杂度不同的物体实例，包括日用品、仪器和工艺品，材质也各不相同，包括金属、塑料、陶瓷和布料；这样做是为了确保所得点云中出现各种感测不完美因素。图5展示了这些物体。

真实扫描——总体而言，增加从多个视点进行扫描的次数，可以得到更好的扫描结果。图4验证了这一点：倒角距离（CD，其定义见在线附录B）随着扫描次数增加而减小。

由于Einscan SE在扫描40次、OKIO 5 M在扫描20次时，所得点云的质量开始趋于饱和，因此扫描某一物体时，我们使用Einscan SE扫描约40次，使用OKIO 5 M扫描约20次。完成物体扫描后，使用CloudCompare[141]对不同次扫描得到的点云进行对齐。表IV给出了基准中真实扫描数据的统计信息。图6展示了两台扫描仪得到的一些数据对。

V. 现有表面重建方法的基准评测实验设置

利用第IV节建立的基准，我们旨在通过实验比较现有表面重建方法，并识别它们在不同工作条件下的优势与劣势，例如基准所考虑的各种扫描不完美因素。我们期待此类研究既能为该领域的未来研究提供启发，也能指导人们在实际应用中选择适合从点观测重建表面的方法。鉴于近来出现了大量新方法，尤其是基于深度学习的方法，此时为研究界开展这样一次全面调查正当其时。

A. 数据

我们使用所收集基准的一个子集开展实验研究，同时公开发布完整基准，以推动研究界开展研究。具体而言，随机采样22个物体实例的合成表面，它们在低、中、高复杂度三组中的分布为12：6：4；如第IV-A节所述，对每个实例进行六种方式的合成扫描，产生干净点云或带有各种不完美因素的点云，共得到308组输入—输出数据对，用于算法基准评测。我们还使用全部50个合成场景表面和全部20个真实扫描表面开展研究。对于使用基于学习的先验的现有方法，我们准备了一个辅助训练数据集，包括来自ShapeNet[18]和ABC[21]的表面，以及基准中其余物体实例的合成数据。具体而言，我们在该辅助数据集上重新训练OccNet[9]和DeepSDF[8]；细节见在线附录C。

B. 预处理

虽然可以直接使用第V-A节准备的数据比较现有表面重建方法，但对其中大多数方法而言，一些标准的点云预处理流程能够显著改善性能。在本研究中，我们比较了使用和不使用此类预处理流程的现有方法。对于合成数据，流程依次为离群点去除、去噪和点重采样，具体细节如下。对于真实扫描数据，使用不同扫描仪的内置预处理，并在最后通过FPS重采样，使每个点云包含200,000个点。

离群点去除——点云中存在极端离群点时，表面重建性能会严重下降；所幸这些离群点容易去除。我们使用统计方法[142]去除极端离群点。对于点云P，当任意点p ∈ P距离其局部邻域非常远时，该方法将其视为离群点并去除。更精确地说，对于任意p ∈ P，首先计算p与其在P中的k个最近邻之间的平均距离$\bar{d}_p$；随后，对所有{p ∈ P}的这类距离计算均值$m_{\bar{d}}$与标准差$\sigma_{\bar{d}}$；当某点对应的$\bar{d}_p > 5 \cdot \sigma_{\bar{d}}$时，将其视为离群点。本研究将用于离群点去除的k设为35。

去噪——不可避免的逐点噪声同样会影响表面重建。对于输入点云P，我们选择Jets平滑[143]来抑制这类噪声，该方法在平滑点云的同时不牺牲表面曲率。其过程是先对P中包含k个点的局部邻域N拟合一个参数化表面片，然后将{p ∈ N}投影到该拟合表面片上。本研究将用于逐点去噪的k设为18。

点重采样——实验结果表明，更均匀的点分布有利于表面重建，即使减少P中所包含的点数也是如此[144]。对于物体或场景表面的合成数据，我们直接采用最远点采样[106]，重采样出分布更均匀的点；重采样时保留原始点的40%。

C. 评估指标

原文 PDF 第 14 页 · 期刊页 9740

我们使用常见的倒角距离（Chamfer Distance，CD）[145]、F分数（F-score）[146]以及法向一致性分数（Normal Consistency Score，NCS）[9]，定量比较不同方法的重建结果。它们的计算方法见在线附录B。我们还提出一种神经指标，称为神经特征相似度（Neural Feature Similarity，NFS），关注每个重建结果与真值之间的感知一致性；直观地说，NFS在深度特征空间中比较两个形状的相似度，因此更依赖与人类感知一致的高层语义信息[147]。我们在在线附录B中给出NFS的细节，并将其与经典指标光场距离（Light Field Distance，LFD）[148]进行比较。与LFD类似，NFS能够捕捉形状由粗到细的细节；与LFD不同，NFS可以用于评估基准中的全部三类数据集，而LFD只能用于物体级合成表面，参见在线附录B。

CD和F分数用于衡量两个形状的整体相似性；NCS通过衡量表面法向的一致性，更适合度量两个相似形状之间的细微差异；NFS衡量与人类感知有关的语义差异。

D. 方法与实现细节

在第III-E节中，我们根据现有方法分别使用了何种几何先验来正则化重建，对这些方法进行了分类。研究并通过实验比较所有现有方法不太可行；因此，我们采用的策略是从每个几何先验方法组中选择代表性方法，并假定我们的研究与结论可以推广到同组的现有方法。具体而言，对于基于三角剖分的先验，采用最具代表性的GD[41]和BPA[42]作为研究对象；对于表面平滑先验，采用使用第一种表面平滑策略的SPSR[39]，参见式（10），以及同时使用两种表面平滑策略的RIMLS[63]，参见式（9）和对H_f的约束；对于建模先验，采用能够从未定向点云重建表面的SALD[83]，以及能够从定向点云重建表面的IGR[37]；对于基于学习的先验，采用进行全局语义学习的OccNet[9]和DeepSDF[8]，以及进行局部学习的LIG[10]和Points2Surf[89]；对于混合先验，考虑三种方法：结合三角剖分先验与学习先验的DSE[123]，结合表面平滑先验与学习先验的IMLSNet[124]，以及结合模板先验与学习先验的ParseNet[47]。我们不考虑只使用模板先验的方法，因为其性能很大程度上取决于待重建表面与假定模板之间是否存在良好匹配，例如假定的几何基元，或可从辅助数据集中检索得到的模板；而且，即使采用基于学习的模板的方法[47]，也无法重建具有某些复杂度的表面。

我们对较为经典、无需学习的方法的实现基于成熟的软件库；例如，使用CGAL库[149]实现GD，并在MeshLab[150]中适当调整参数后，直接运行BPA[42]、SPSR[39]和RIMLS[63]。对于基于学习的方法，只要作者公开发布了实现代码，我们就使用这些代码，并同样针对每个待重建表面适当调整超参数。对于未公开代码的方法，我们重新实现其算法，并将各自的超参数调至最优。

第VI节报告并讨论的是使用第V-B节预处理后得到的结果。我们注意到，不经预处理的结果在相对比较上具有类似表现，并将其放在在线附录F中。

VI. 主要结果

在介绍一系列实验的细节之前，我们首先总结关键的实验发现，随后据此给出启示。

• 虽然通过使用不同的表面几何正则化或先验，能够在不同程度上应对点云表面重建的许多挑战，但配准错位、点缺失和离群点这些挑战得到的关注较少，仍未解决。

• 基于深度学习的数据驱动解决方案近来在表面建模与重建方面显示出很大潜力，包括应对各种数据不完美因素的潜力。然而，我们的系统实验表明，它们难以泛化到复杂形状的重建；令人意外的是，SPSR[39]等一些经典方法在泛化能力和鲁棒性方面表现得更好。

• 使用表面法向是成功地从原始观测点云重建表面的关键，即使法向估计并不十分准确也是如此；在许多情况下，只要能够在三维空间中识别表面的内部和外部，重建结果就会改善。

• 不同评估指标之间存在不一致，而且在许多情况下，良好的定量结果并不意味着视觉上令人满意。例如，使用CD和F分数衡量的定量结果受配准错位挑战的影响不大；但NCS和NFS分数的下降表明，恢复的表面可能在人类感知上不那么令人满意。

参与比较的方法的定量结果见表V、VI和VII，分别对应物体表面的合成数据、场景表面的合成数据以及真实扫描数据。定性结果将在以下各节中结合讨论给出。

A. 尚未解决的挑战

为便于分析，我们在图7中绘制了表V中CD、F分数、NCS和NFS四项指标的定量结果。如第V-C节所述，这四项指标着眼于不同的衡量角度。通过使用这些指标诊断参与比较的方法，并考察它们应对不完美扫描所带来不同挑战的能力，图7有助于识别尚未解决的挑战。

图7表明，在所有指标下，除学习语义或几何基元的方法——即DeepSDF[8]、OccNet[9]和ParseNet[47]——之外，几乎所有方法都比较容易应对点的非均匀分布这一挑战，所得结果与在完美扫描数据上的结果相似。

原文 PDF 第 15 页 · 期刊页 9741

表 5

Prior	Method	CD ($\times 10^{-4}$) ↓						F-score (%) ↑					
		Perfect scanning	Non-uniform distribution	Point-wise noise	Point outliers	Missing points	Mis-alignment	Perfect scanning	Non-uniform distribution	Point-wise noise	Point outliers	Missing points	Mis-alignment
Triangulation-based	GD [41]	**14.24**	**14.87**	18.20	123.19	64.15	21.15	**99.66**	**99.07**	98.91	54.59	87.72	97.41
	BPA [42]	14.89	17.13	18.58	**14.66**	**62.55**	20.88	98.70	97.02	98.51	**99.31**	**87.85**	97.24
Smoothness	SPSR [39]	14.47	15.36	**16.05**	**14.71**	225.66	**17.24**	99.59	99.02	**99.46**	**99.65**	76.91	**99.27**
	RIMLS [63]	15.73	16.74	**17.17**	126.40	65.36	21.12	99.27	98.76	**99.24**	57.78	**87.92**	97.53
Modeling	SALD [83]	15.10	**14.96**	18.77	53.65	**55.63**	20.09	99.45	**99.10**	98.94	88.05	85.78	98.09
	IGR [37]	18.40	18.33	18.57	43.60	151.53	20.72	97.54	97.79	97.75	91.11	70.49	96.46
Learning Semantics	OccNet [9]	201.96	210.80	205.21	225.85	231.65	212.51	31.03	29.90	29.77	23.75	24.52	29.19
	DeepSDF [8]	229.18	227.42	230.40	511.36	378.58	232.16	17.79	18.81	17.08	4.15	14.06	17.05
Local Learning	LIG [10]	23.09	24.03	22.05	115.38	70.98	24.30	96.20	95.32	96.99	76.69	82.43	95.01
	Points2Surf [89]	17.18	18.81	18.48	83.91	102.18	20.36	98.14	97.72	97.39	72.94	76.46	96.49
Hybird	DSE [123]	**14.26**	15.34	17.89	100.37	68.88	**20.06**	**99.64**	98.84	99.17	52.21	87.71	**98.20**
	IMLSNet [124]	22.56	23.17	22.67	99.95	74.35	23.77	94.82	94.51	94.36	64.55	80.01	94.14
	ParseNet [47]	162.94	161.14	135.84	176.38	195.98	136.86	40.52	38.82	44.13	37.21	41.28	46.60

Prior	Method	NCS ($\times 10^{-2}$) ↑						NFS ($\times 10^{-2}$) ↑					
		Perfect scanning	Non-uniform distribution	Point-wise noise	Point outliers	Missing points	Mis-alignment	Perfect scanning	Non-uniform distribution	Point-wise noise	Point outliers	Missing points	Mis-alignment
Triangulation-based	GD [41]	98.57	98.05	87.58	92.17	**95.17**	84.96	95.22	95.19	84.63	37.47	**82.93**	80.69
	BPA [42]	98.37	97.89	91.68	**98.07**	94.42	90.12	94.10	93.60	87.49	**93.24**	80.36	81.96
Smoothness	SPSR [39]	98.58	**98.38**	**97.03**	**98.56**	89.99	**96.24**	**96.38**	**96.22**	**94.98**	**96.31**	69.34	**94.28**
	RIMLS [63]	98.19	97.77	95.23	83.42	93.27	92.48	95.01	94.02	92.67	62.01	79.23	87.12
Modeling	SALD [83]	**98.67**	**98.52**	96.42	95.32	**95.19**	94.73	**96.11**	**96.65**	89.72	51.74	**84.01**	88.26
	IGR [37]	97.62	97.59	**97.52**	96.47	90.61	**97.04**	94.71	94.22	**94.52**	84.63	68.14	**92.54**
Learning Semantics	OccNet [9]	79.55	79.30	79.64	78.55	78.43	79.58	47.33	46.55	46.03	42.11	42.46	45.80
	DeepSDF [8]	78.65	79.11	77.78	73.40	74.52	78.12	39.94	40.91	39.29	16.65	31.59	39.26
Local Learning	LIG [10]	96.49	95.79	94.22	91.66	89.56	92.70	91.58	90.66	89.55	66.21	74.98	84.34
	Points2Surf [89]	95.24	95.09	94.62	87.87	86.36	94.48	93.45	93.23	92.59	63.30	68.53	91.59
Hybird	DSE [123]	**98.60**	97.86	87.79	77.34	94.40	86.20	94.50	94.75	83.53	42.32	79.62	76.63
	IMLSNet [124]	96.13	95.98	96.02	87.45	90.48	95.87	90.61	90.20	89.97	52.82	74.59	89.19
	ParseNet [47]	77.71	76.89	80.31	75.46	75.83	80.48	38.54	37.71	49.30	35.98	38.40	45.73

Comparisons are made on data of perfect scanning and those of all the five challenges of imperfect scanning specified in Section 4.1.3; for those challenges with varying levels of severity, we use the data of middle-level severity for the comparison (cf. Appendix D for the overall results). Results of the best and second best methods are highlighted in each column. Comparative methods are also grouped according to what priors of surface geometry they have used (cf. Section 3 for the grouping and Section 5.4 for how these representative methods are selected).

表 V 物体表面合成测试数据上的定量结果。

列名：Prior = 先验；Method = 方法。先验分组依次为：基于三角剖分、光滑性、建模、学习语义、局部学习、混合。扫描条件包括：Perfect scanning = 完美扫描；Non-uniform distribution = 非均匀分布；Point-wise noise = 逐点噪声；Point outliers = 离群点；Missing points = 缺失点；Misalignment = 错位/配准误差。CD（Chamfer距离）的标度为 $\times 10^{-4}$，↓表示越低越好；F-score 的单位为%，↑表示越高越好；NCS（法向一致性得分）和 NFS（神经特征相似度）的标度均为 $\times 10^{-2}$，↑表示越高越好。

表中比较了完美扫描数据，以及第4.1.3节所述五类非理想扫描挑战下的数据；对于具有不同严重程度的挑战，采用中等严重程度的数据进行比较（整体结果见附录 D）。每一列中最优与次优方法的结果均已突出显示。比较方法还按照其采用的表面几何先验分组（分组见第3节，代表性方法的选择见第5.4节）。

表 6

Prior	Method	CD ($\times 10^{-3}$) ↓	F-score (%) ↑	NCS ($\times 10^{-2}$) ↑	NFS ($\times 10^{-2}$) ↑
Triangulation-based	GD [41]	51.54	58.89	57.81	37.74
	BPA [42]	77.97	33.36	54.41	33.28
Smoothness	SPSR [39]	**49.46**	**64.41**	74.23	**47.82**
	RIMLS [63]	67.46	53.61	58.16	27.37
Modeling	SALD [83]	50.42	61.14	**86.47**	45.98
	IGR [37]	**50.06**	**62.67**	**84.36**	**46.31**
Learning Semantics	OccNet [9]	108.29	29.16	79.48	35.08
	DeepSDF [8]	-	-	-	-
Local Learning	LIG [10]	69.38	57.57	79.24	43.92
	Points2Surf [89]	66.22	56.27	75.53	45.64
Hybird	DSE [123]	51.72	57.49	55.44	37.64
	IMLSNet [124]	59.95	59.88	80.80	44.86
	ParseNet [47]	-	-	-	-

Results of the best and second best methods are highlighted in each column. Comparative methods are grouped according to what priors of surface geometry they have used (cf. Section 3 for the grouping and Section 5.4 for how these representative methods are selected). "-" indicates the method cannot produce reasonable results due to their limited generalization.

表 VI 场景表面合成测试数据上的定量结果。

列名：Prior = 先验；Method = 方法；先验分组为基于三角剖分、光滑性、建模、学习语义、局部学习、混合。CD（Chamfer 距离）的标度为 $\times 10^{-3}$，↓表示越低越好；F-score 的单位为%，↑表示越高越好；NCS（法向一致性得分）和 NFS（神经特征相似度）的标度均为 $\times 10^{-2}$，↑表示越高越好。

每一列中最优与次优方法的结果均已突出显示。比较方法按照其采用的表面几何先验分组（分组见第3节，代表性方法的选择见第5.4节）。"—"表示该方法因泛化能力有限而无法产生合理结果。

表 7

Prior	Method	CD ($\times 10^{-2}$) ↓	F-score (%) ↑	NCS ($\times 10^{-2}$) ↑	NFS ($\times 10^{-2}$) ↑
Triangulation-based	GD [41]	31.72	87.51	88.86	82.20
	BPA [42]	40.37	80.95	87.56	68.69
Smoothness	SPSR [39]	**31.05**	**87.74**	**94.94**	**89.38**
	RIMLS [63]	32.80	87.05	91.97	85.19
Modeling	SALD [83]	**31.13**	**87.72**	94.68	86.86
	IGR [37]	32.70	87.18	**95.99**	**89.10**
Learning Semantics	OccNet [9]	232.71	17.11	80.96	39.70
	DeepSDF [8]	263.92	19.83	77.95	40.95
Local Learning	LIG [10]	48.75	83.76	92.57	81.48
	Points2Surf [89]	48.93	80.89	89.52	81.83
Hybird	DSE [123]	32.16	86.88	87.20	76.81
	IMLSNet [124]	38.46	82.44	93.31	85.30
	ParseNet [47]	149.96	38.92	81.51	45.67

Results of the best and second best methods are highlighted in each column. Comparative methods are grouped according to what priors of surface geometry they have used (cf. Section 3 for the grouping and Section 5.4 for how these representative methods are selected).

表 VII 真实扫描数据上的定量结果。
列名：Prior = 先验；Method = 方法；先验分组为基于三角剖分、光滑性、建模、学习语义、局部学习、混合。CD（Chamfer 距离）的标度为 $\times 10^{-2}$，↓表示越低越好；F-score 的单位为%，↑表示越高越好；NCS（法向一致性得分）和 NFS（神经特征相似度）的标度均为 $\times 10^{-2}$，↑表示越高越好。
每一列中最优与次优方法的结果均已突出显示。比较方法按照其采用的表面几何先验分组（分组见第3节，代表性方法的选择见第5.4节）。

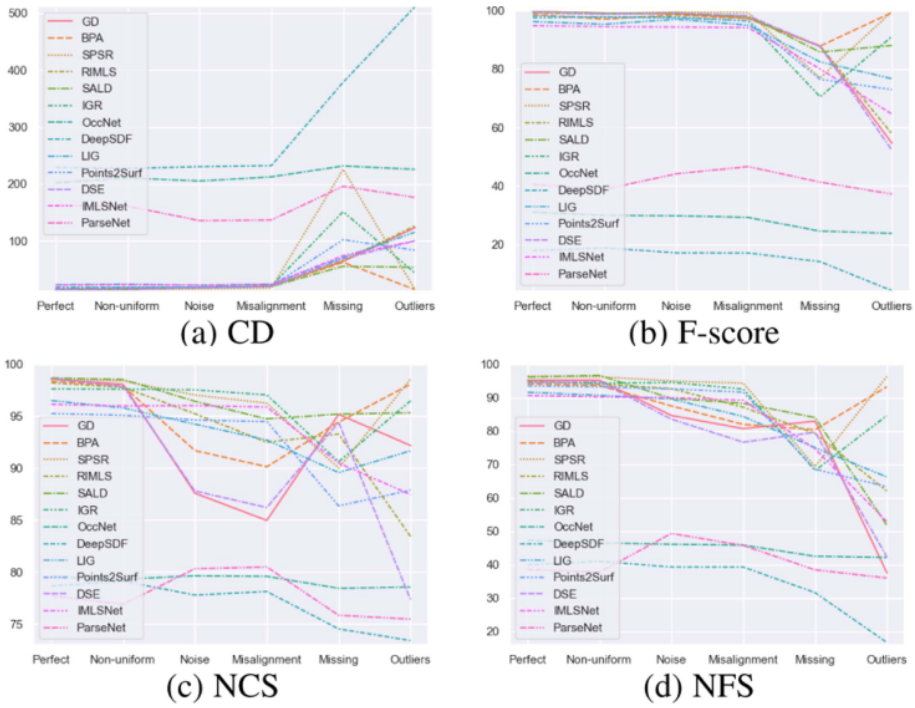


图7 表 V 中定量结果的图示。

关于部分基于学习的方法为何无法泛化的讨论见第 VI-B 节。对于逐点噪声这一挑战，尽管大多数方法能够大致恢复整体形状结构（以 CD 和 F-score 衡量；同样，某些基于学习的方法除外），重建结果仍可能缺少表面细节，NCS 和 NFS 得分的下降验证了这一点。对于 GD [41]、BPA [42] 等基于三角剖分的方法，以及结合三角

剖分先验的混合方法 DSE [123]，这一现象尤其明显。这很容易理解，因为基于点的三角剖分的方法高度依赖输入点的洁净程度。

对于错位/配准误差这一挑战，也存在类似但更严重的现象。如图7所示，以 CD 和 F-score 衡量时，大多数方法都取得了相当不错的结果，说明整体形状结构已被恢复。然而，NCS 和 NFS 得分的下降表明，一些恢复的表面可能在人的视觉感知上不够理想。事实上，如图8中的示例所示，大多数方法无法正确重建错位区域的表面，产生了变厚的局部表面，甚至形成多层局部表面。错位/配准误差是三维扫描中的实际问题，尤其在使用手持消费级扫描仪时。图7和图8表明，采用光滑性先验和/或建模先验的方法在处理错位/配准误差时具有优势。

原文 PDF 第 16 页 · 期刊页 9742

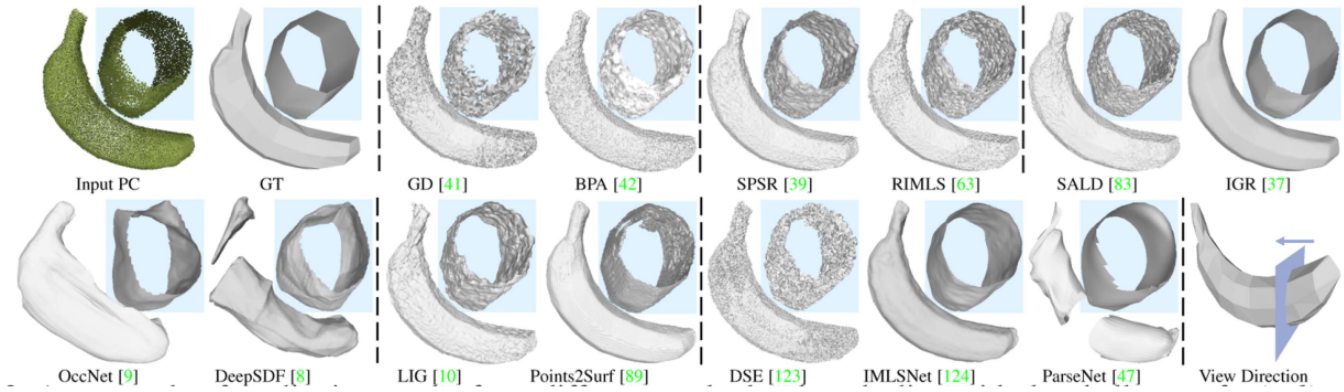


图8 不同方法应对错位/配准误差挑战时的定性结果示例。

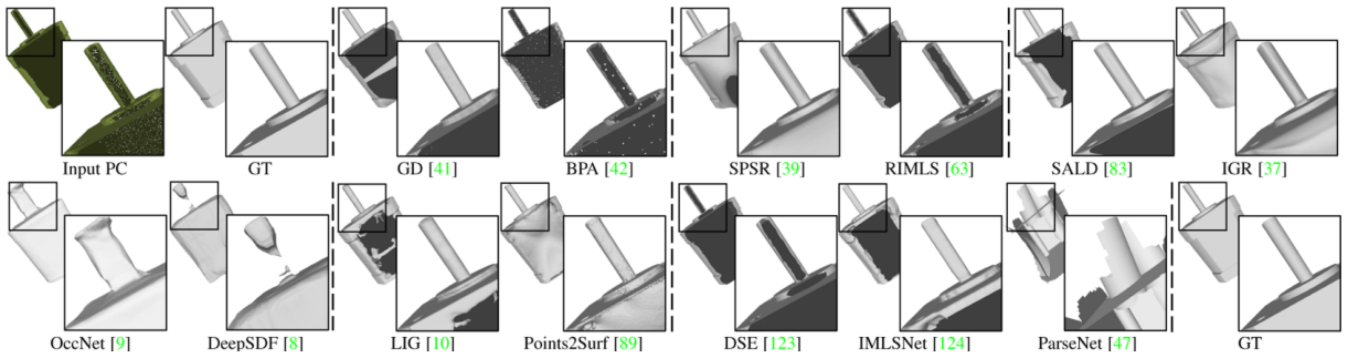


图9 不同方法应对缺失点挑战时的定性结果示例。

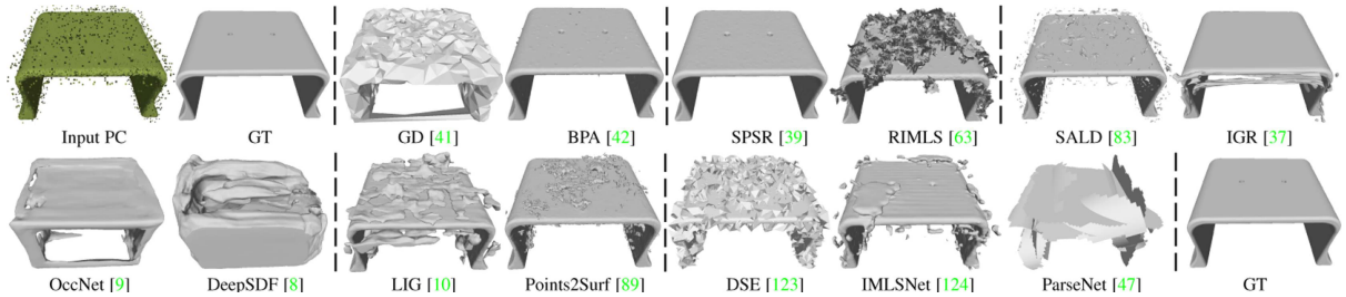


图10 不同方法应对离群点挑战时的定性结果示例。

图7还表明，缺失点与离群点这两类挑战更难处理。当输入点云存在缺失点时，如图9所示，大多数方法会忽略缺失表面区域的重建，导致表面不完整。隐式方法（如 IGR [37]、OccNet [9] 和 Points2Surf [89]）往往用凹包或凸包填补孔洞，生成水密表面；然而，这样的包络可能无法正确表示表面，甚至可能使所有评价指标下的重建结果更差（参见图7）。

对于离群点，尽管所有参与比较的方法都已采用去除离群点的预处理步骤（参见第 V-B 节），不同方法的性能仍有很大差异。图10给出了一个示例；结果取决于各方法是否具备内置的离群点去除机制。例如，BPA [42] 要求其三角形面的尺寸满足某些条件，因此天然适于处理离群点；采用全局隐式场的方法（如 SPSR [39] 和 IGR [37]）会隐式地忽略离群点，因此也能够处理离群点。

总结以上分析，我们得到以下经验性发现：1）所有参与比较的方法都未解决缺失点这一挑战；2）对于错位/配准误差与离群点这两类挑战，大多数方法的结果不令人满意，只有 SPSR [39] 等少数方法例外；3）不同评价指标之间存在不一致，在许多情况下，较好的定量结果并不对应视觉上令人满意的结果；4）当测试点云不属于已学习的数据域时，学习语义或预定义形状模式的方法即使面对完美扫描的洁净数据，也可能无法泛化；我们将稍后进一步讨论这一问题。

B. 基于优化、无需学习的方法与基于学习、数据驱动的方法

在本节中，我们将参与比较的方法分成两组：基于优化、无需学习的方法，以及基于学习、数据驱动的方法，以研究它们的表现。前一组包括 SPSR [39]、RIMLS [63]、SALD [83] 和 IGR [37]；为完整涵盖所研究的方法，我们也将 GD [41] 和 BPA [42] 纳入该组。后一组包括 OccNet [9]、DeepSDF [8]、LIG [10]、Points2Surf [89]、DSE [123]、IMLSNet [124] 和 ParseNet [47]。

原文 PDF 第 17 页 · 期刊页 9743

表 8

Algorithms	Priors	CD ($\times 10^{-4}$) ↓	F-score (%) ↑	NCS ($\times 10^{-2}$) ↑	NFS ($\times 10^{-2}$) ↑
		low- /middle- / high-level	*low- /middle- / high-level*	*low- /middle- / high-level*	*low- /middle- / high-level*
GD [41]	learning-free	16.52 / 1.68 / 13.21	99.09 / -0.18 / -7.44	94.00 / -6.42 / -25.68	91.57 / -6.94 / -35.27
BPA [42]		16.59 / 1.99 / 12.71	98.63 / -0.12 / -9.04	95.36 / -3.68 / -17.39	90.71 / -3.22 / -25.56
SPSR [39]		**15.50** / 0.55 / 2.66	**99.51** / -0.05 / **-0.35**	**97.84** / -0.81 / -3.95	**95.60** / -0.62 / -3.61
RIMLS [63]		16.13 / 1.04 / 9.75	99.36 / -0.12 / -4.67	97.36 / -2.13 / -11.23	94.19 / -1.52 / -14.43
SALD [83]		**15.33** / 3.44 / 12.26	**99.54** / -0.60 / -7.06	**98.07** / -1.65 / -9.16	**95.66** / -5.94 / -28.48
IGR [37]		18.21 / 0.36 / 0.99	97.87 / -0.12 / **-0.35**	97.64 / -0.12 / -0.54	94.37 / 0.15 / -0.70
OccNet [9]	learning-based	209.04 / -3.83 / 0.97	29.85 / -0.08 / -1.93	79.43 / 0.21 / -0.38	46.17 / -0.14 / -1.13
DeepSDF [8]		241.28 / **-10.88** / **-1.65**	16.70 / **0.38** / -0.71	78.01 / -0.23 / **0.51**	38.55 / 0.74 / **0.15**
LIG [10]		23.96 / -1.91 / 2.31	94.50 / **2.49** / -0.70	93.96 / **0.26** / -5.70	86.71 / **2.84** / -5.68
Points2Surf [89]		17.74 / 0.74 / 4.89	98.02 / -0.63 / -3.81	94.97 / -0.35 / -1.53	92.83 / -0.24 / -2.62
DSE [123]		16.07 / 1.82 / 11.54	99.40 / -0.23 / -6.65	94.43 / -6.64 / -23.04	90.05 / -6.52 / -32.97
IMLSNet [124]		22.64 / 0.03 / 1.09	94.41 / -0.05 / **-0.01**	96.08 / -0.06 / -0.46	90.13 / -0.16 / -0.47
ParseNet [47]		154.11 / **-18.27** / **-14.14**	44.80 / -0.67 / -2.14	78.55 / **1.76** / **2.60**	46.21 / **3.09** / **2.79**

We report quantitative results for the imperfect scanning of point-wise noise at three levels of severity; results are in the format of "· / · / ·", where the most left one is the absolute value under each evaluation metric, and the right two ones are those relative to the most left one. The best and second best methods are highlighted in each column.

表 VIII 在物体表面合成测试数据上，基于优化、无需学习的方法与基于学习、数据驱动的方法的比较。
列名：Algorithms = 算法；Priors = 先验；分组为 learning-free = 无需学习、learning-based = 基于学习。CD（Chamfer距离）的标度为 $\times 10^{-4}$，↓表示越低越好；F-score 的单位为%，↑表示越高越好；NCS（法向一致性得分）和 NFS（神经特征相似度）的标度均为 $\times 10^{-2}$，↑表示越高越好。每种指标均依次列出 low- / middle- / high-level，即低、中、高三档严重程度。
表中报告了逐点噪声非理想扫描在三档严重程度下的定量结果；结果以"· / · / ·"的形式给出，其中最左侧为各评价指标下的绝对值，右侧两个数为相对于最左侧结果的变化值。每一列中最优与次优方法的结果均已突出显示。

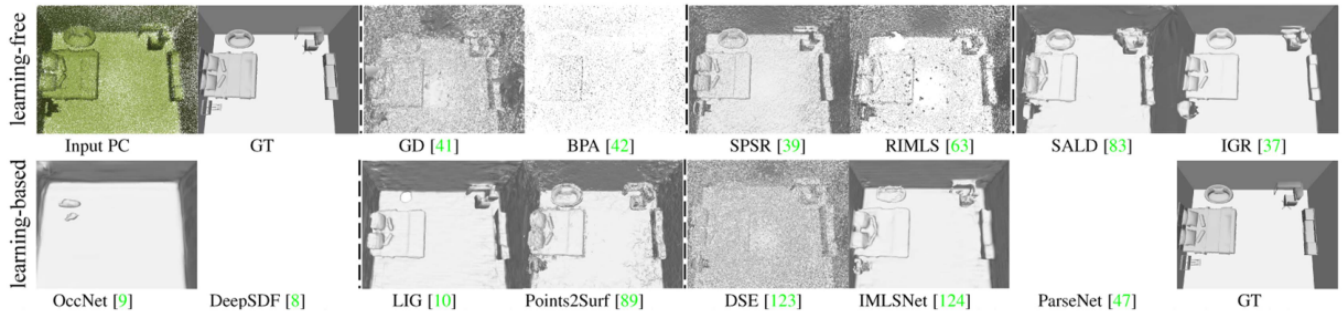


图11 基于优化、无需学习的方法，以及基于学习、数据驱动的方法，在场景表面合成测试数据上的定性结果。该场景是来自 3D-FRONT [25] 的一个卧室实例。

这样分组旨在研究两类方法在泛化到复杂形状时的表现。其中，我们特别关注全局语义学习方法（即 OccNet [9] 和 DeepSDF [8]），因为其优势可能只有在辅助训练集中包含相应物体表面类别时才能体现。需要注意的是，如第 V-A 节所述，我们的物体表面合成测试数据包含22个随机选取的物体，其中既有属于常见语义类别的物体（例如椅子），也有不具备明确定义语义的物体。对于前者，我们的辅助训练集中包含来自 ShapeNet [18] 的大量同类别形状实例。在本节中，我们还研究两类方法对不同严重程度的非理想扫描的鲁棒性。

表 VIII 的定量结果表明，在合成物体表面重建中，基于优化、无需学习的方法在不同评价指标下具有更好的泛化表现，因为我们的测试形状既包含具有语义的形状，也包含不具有语义的复杂形状。图12中的示例也呈现了一致的现象：基于学习、数据驱动的方法擅长重建椅子的表面，却无法泛化到不具有语义的形状。表 VIII 还表明，基于学习的方法对于更严重的数据不完美具有较好的鲁棒性。这意味着，当输入提供的信息较少时，基于学习的方法表现更好；例如，如文献 [11] 所讨论的，当输入点云变得更加稀疏时。按照这两类方法重新组织表 VII 后，我们在真实扫描数据的重建中也观察到了类似现象（更多细节见在线附录 G）。

为进一步研究从辅助数据中学习的表现，我们开展了合成场景表面重建实验。表 VI 的结果（按方法组重新组织后）和图11表明，在基于学习的方法中，LIG [10]、Points2Surf [89] 和 IMLSNet [124] 能够通过局部建模与聚合处理场景级表面重建；而语义学习方法 OccNet 和 DeepSDF 则如预期那样失败。

我们将以上分析总结如下：1）当训练集中包含同一语义类别的物体实例时，基于学习、数据驱动的方法能够重建物体表面，并对数据不完美表现出一定程度的鲁棒性；然而，当这一条件不满足时，这些方法无法泛化。2）对于场景级表面重建，局部学习方法可通过局部建模与聚合取得成功；相比之下，全局语义学习方法无法做到这一点。3）某些基于优化、无需学习的方法（例如 SPSR [39]）在物体级与场景级表面重建中的鲁棒性和泛化表现出人意料地好。

原文 PDF 第 18 页 · 期刊页 9744

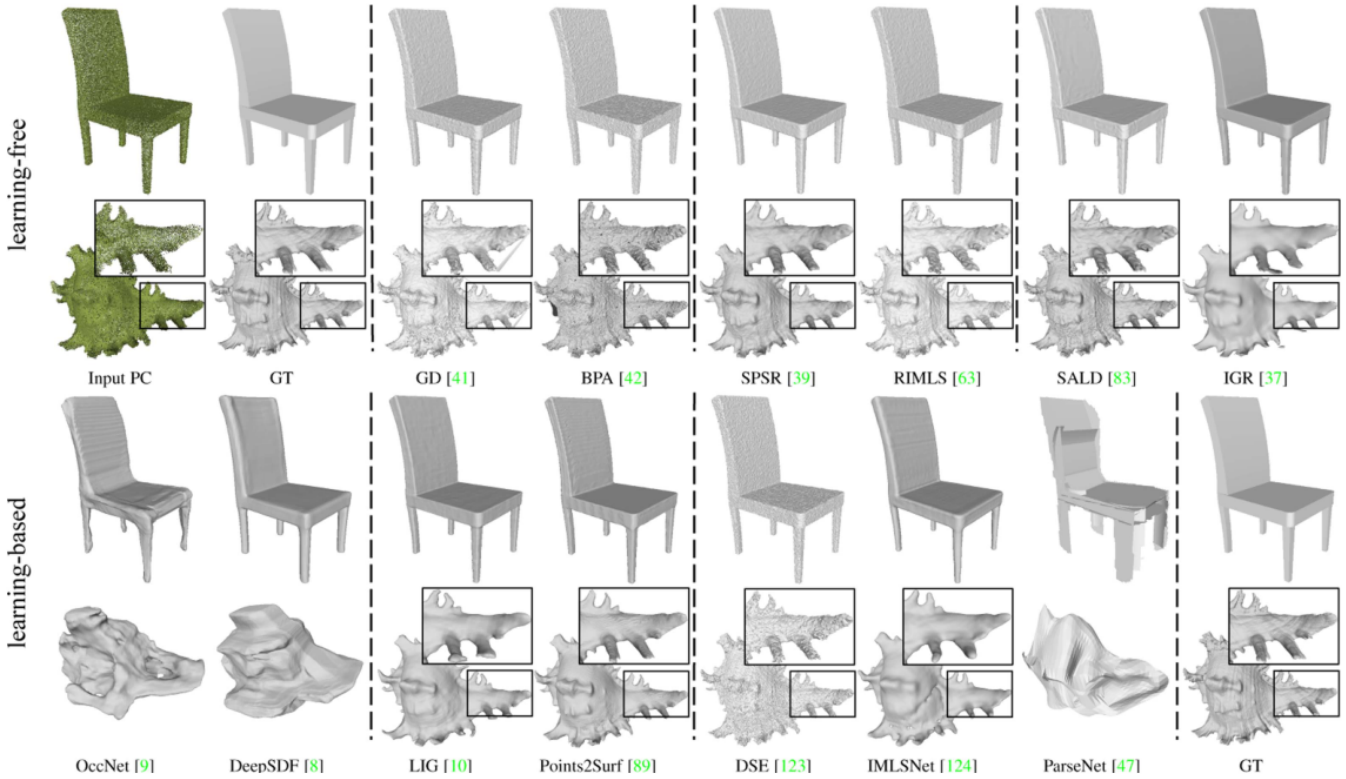


图12 基于优化、无需学习的方法，以及基于学习、数据驱动的方法，在物体表面合成测试数据上的定性结果。输入点云具有逐点噪声这一非理想扫描问题。椅子示例属于常见语义类别，我们的辅助训练集中包含来自 ShapeNet [18] 的大量同类别实例；另一个示例则不具有语义。

C. 表面法向朝向的重要性

我们研究的部分方法从观测点云计算表面法向，并将计算得到的法向用于表面重建，包括 BPA [42]、SPSR [39]、RIMLS [63]、IGR [37]、OccNet [9]、DeepSDF [8]、LIG [10] 和 ParseNet [47]。另有少数方法（例如 Points2Surf [89] 和 IMLSNet [124]）在训练数据上计算表面法向，再训练模型，以便在重建测试表面时估计表面法向。为研究这些方法如何受益于表面法向的计算或估计，我们在具有非理想扫描问题的测试数据上开展实验，因为从非理想扫描数据中计算得到的表面法向不够准确，能够检验这些方法的鲁棒性。假设已知相机相对于观测点云的位姿；对于任意观测点，我们对其局部点邻域进行主成分分析（PCA），计算该点的定向法向（细节见第 IV-A3 节）。由此得到的表面法向可能不够精确，但其朝内或朝外的方向必定正确。

表 IX 给出了物体表面合成数据上的定量结果。在不同评价指标下，额外计算或估计表面法向确实有助于改善表面重建。当无法获得相机相对于观测表面点的位姿时，某些局部表面邻域中的法向朝向会被错误地确定，因为在含噪点的局部邻域上进行 PCA 所得的主方向不够可靠。为研究表面法向朝内或朝外这一朝向的重要性，我们还在表 IX 中报告了相关实验，其中“/”符号右侧的每个结果均在未知相机相对位姿的情况下获得；与“/”左侧假设已知真实相机位姿所得的结果相比，右侧结果显著下降。我们还在场景表面合成数据与真实扫描数据上开展了实验，并观察到类似现象；这些结果见在线附录 E。

表 9

Algorithms	Normals	CD ($\times 10^{-4}$) ↓	F-score (%) ↑	NCS ($\times 10^{-2}$) ↑	NFS ($\times 10^{-2}$) ↑
GD [41]	×	18.20 /	98.91 /	87.58 /	84.63 /
SALD [83]	×	18.77 /	98.94 /	96.42 /	89.72 /
DSE [123]	×	17.89 /	99.17 /	87.79 /	83.53 /
BPA [42]	✓	18.58 / 18.61	98.51 / 98.56	91.68 / 91.79	87.49 / 85.08
SPSR [39]	✓	**16.05** / 60.42	**99.46** / 91.45	**97.03** / 94.68	**94.98** / 84.34
RIMLS [63]	✓	**17.17** / 18.58	**99.24** / 97.47	95.23 / 94.06	92.67 / 86.63
IGR [37]	✓	18.57 / 262.40	97.75 / 85.98	**97.52** / 95.28	**94.52** / 79.61
OccNet [9]	✓	205.21 / 214.12	29.77 / 28.83	79.64 / 79.01	46.03 / 45.12
DeepSDF [8]	✓	230.40 / 569.41	17.08 / 15.64	77.78 / 77.09	39.29 / 33.78
LIG [10]	✓	22.05 / 34.78	96.99 / 89.60	94.22 / 91.36	89.55 / 80.02
ParseNet [47]	✓	135.84 / 197.28	44.13 / 35.67	80.31 / 76.19	49.30 / 41.65
Points2Surf [89]	*	18.48 /	97.39 /	94.62 /	92.59 /
IMLSNet [124]	*	22.67 /	94.36 /	96.02 /	89.97 /

We report quantitative results for the imperfect scanning of point-wise noise at the middle level of severity; results are in the format of "· / ·", where the left one is obtained assuming the availability of ground-truth camera poses, and the right one is obtained without knowing the camera poses. The best and second best methods are highlighted in each column.

表 IX 在物体表面合成测试数据上，不使用表面法向的方法（×）、使用表面法向的方法（√），以及仅在学习期间使用表面法向的方法（*）之间的比较。
列名：Algorithms = 算法；Normals = 法向。CD（Chamfer距离）的标度为 $\times 10^{-4}$，↓表示越低越好；F-score 的单位为%，↑表示越高越好；NCS（法向一致性得分）和 NFS（神经特征相似度）的标度均为 $\times 10^{-2}$，↑表示越高越好。
表中报告了中等严重程度逐点噪声非理想扫描的定量结果，结果以"· / ·"的形式给出：左侧结果使用真实相机位姿获得，右侧结果在未知相机位姿的情况下获得。每一列中最优与次优方法的结果均已突出显示。

根据以上分析，我们得到以下经验性发现：1）计算或估计定向法向有助于从点云重建表面；2）相较于表面法向的精度，正确确定其朝内或朝外的方向更为重要。

VII. 结论

本文综述了从点云重建表面的经典方法，以及较新的基于深度学习的方法。我们按照这些方法用于正则化求解的表面几何先验对其进行分类，并据此组织综述。为更好地理解现有方法各自的优势与局限，我们提出了一个由合成数据和真实扫描数据组成的大规模基准数据集，涵盖了实际三维扫描中常见的各种感知不完美问题。我们在构建的基准上开展了全面的实证研究，评价不同方法的鲁棒性与泛化能力。这些研究有助于确定现有方法仍然面临的挑战，我们希望它们能够为未来研究方向提供指导。

作者简介（原文 PDF 第 22 页）

作者简介

ZhangJin Huang 于2021年获得中国广州华南理工大学电子与信息工程学院的毕业学位（原文为 graduate degree）。目前，他正在华南理工大学攻读电子信息硕士学位。他的研究兴趣包括计算机视觉与机器学习。

Yuxin Wen 目前正在华南理工大学电子与信息工程学院攻读信息与通信工程博士学位。他的研究兴趣为计算机视觉与机器学习，重点关注利用深度学习进行物体和场景的形状建模与重建。

ZiHao Wang 目前正在华南理工大学电子与信息工程学院攻读电子信息硕士学位。他的研究兴趣包括计算机视觉、深度传感器与机器学习。

Jinjuan Ren 于2001年获得复旦大学文学学士学位，2004年获得香港大学哲学硕士学位，2009年获得香港大学博士学位。自2015年起，她一直担任澳门大学副教授；2009年至2015年期间担任澳门大学助理教授。她的研究领域包括金融科技、机器学习与行为金融。她曾在 Management Science 等顶级期刊发表论文，并持有特许金融分析师（CFA）资格。

Kui Jia 于2001年获得中国西北工业大学海洋工程工学学士学位，2003年获得新加坡国立大学电子与计算机工程工学硕士学位，2007年获得英国伦敦玛丽女王大学计算机科学博士学位。目前，他是华南理工大学电子与信息工程学院教授。他的研究兴趣为计算机视觉与机器学习。近期研究重点为深度学习理论及其在三维视觉中的应用。他一直担任 IEEE Transactions on Image Processing 和 Transactions on Machine Learning Research 的副编辑。

参考文献（英文原题录）

以下保留原文第 19–22 页的参考文献题录及英文作者简介。中文正文的引用编号可直接在这里查找。

c
g
u
r
s
v
p
c
g
r
t
f

REFERENCES

[1] R. Bolle and B. Vemuri, "On three-dimensional surface reconstruction methods," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 13, no. 1, pp. 1–13, Jan. 1991.

[2] S. P. Lim and H. Haron, "Surface reconstruction techniques: A review," *Artif. Intell. Rev.*, vol. 42, no. 1, pp. 59–78, 2014.

[3] M. Berger et al., "A survey of surface reconstruction from point clouds," *Comput. Graph. Forum*, vol. 36, no. 1, pp. 301–329, 2017.

[4] C. C. You, S. P. Lim, S. C. Lim, J. San Tan, C. K. Lee, and Y. M. J. Khaw, "A survey on surface reconstruction techniques for structured and unstructured data," in *Proc. IEEE Conf. Open Syst.*, 2020, pp. 37–42.

[5] T. Groueix, M. Fisher, V. G. Kim, B. C. Russell, and M. Aubry, "A Papier-Mâché approach to learning 3D surface generation," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2018, pp. 216–224.

[6] Y. Luo, Z. Mi, and W. Tao, "DeepDT: Learning geometry from delaunay triangulation for surface reconstruction," in *Proc. 35th AAAI Conf. Artif. Intell.*, 2021, pp. 2277–2285.

[7] N. Sharp and M. Ovsjanikov, "PointTriNet: Learned triangulation of 3D point sets," in *Proc. Eur. Conf. Comput. Vis.*, Springer, 2020, pp. 762–778.

[8] J. J. Park, P. Florence, J. Straub, R. Newcombe, and S. Lovegrove, "DeepSDF: Learning continuous signed distance functions for shape representation," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2019, pp. 165–174.

[9] L. Mescheder, M. Oechsle, M. Niemeyer, S. Nowozin, and A. Geiger, "Occupancy networks: Learning 3D reconstruction in function space," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2019, pp. 4460–4470.

[10] C. Jiang, A. Sud, A. Makadia, J. Huang, M. Nießner, and T. Funkhouser, "Local implicit grid representations for 3D scenes," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2020, pp. 6001–6010.

[11] R. Sulzer, L. Landrieu, R. Marlet, and B. Vallet, "A survey and benchmark of automatic surface reconstruction from point clouds," 2023, *arXiv:2301.13656*.

[12] G. Slabaugh, R. Schafer, T. Malzbender, and B. Culbertson, "A survey of methods for volumetric scene reconstruction from photographs," in *Proc. Volume Graph.*, Springer, 2001, pp. 81–100.

[13] F. Remondino and S. El-Hakim, "Image-based 3D modelling: A review," *Photogrammetric Rec.*, vol. 21, no. 115, pp. 269–291, 2006.

[14] S. M. Seitz, B. Curless, J. Diebel, D. Scharstein, and R. Szeliski, "A comparison and evaluation of multi-view stereo reconstruction algorithms," in *Proc. IEEE Comput. Soc. Conf. Comput. Vis. Pattern Recognit.*, 2006, pp. 519–528.

[15] X. Han, H. Laga, and M. Bennamoun, "Image-based 3D object reconstruction: State-of-the-art and trends in the deep learning era," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 43, no. 5, pp. 1578–1604, May 2021.

[16] G. Fahim, K. Amin, and S. Zarif, "Single-view 3D reconstruction: A survey of deep learning methods," *Comput. Graph.*, vol. 94, pp. 164–190, 2021.

[17] H. Zhu, Y. Nie, T. Yue, and X. Cao, "The role of prior in image based 3D modeling: A survey," *Front. Comput. Sci.*, vol. 11, no. 2, pp. 175–191, 2017.

[18] A. X. Chang et al., "ShapeNet: An information-rich 3D model repository," 2015, *arXiv:1512.03012*.

[19] Z. Wu et al., "3D ShapeNets: A deep representation for volumetric shapes," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2015, pp. 1912–1920.

[20] W. Wohlkinger, A. Aldoma, R. B. Rusu, and M. Vincze, "3DNet: Large-scale object class recognition from CAD models," in *Proc. IEEE Int. Conf. Robot. Automat.*, 2012, pp. 5384–5391.

[21] S. Koch et al., "ABC: A big CAD model dataset for geometric deep learning," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2019, pp. 9601–9611.

[22] Q. Zhou and A. Jacobson, "Thingi10K: A dataset of 10, 000 3D-printing models," 2016, *arXiv:1605.04797*.

[23] V. Albertina et al., "Three D scans," 2012. [Online]. Available: https://threedscans.com/

[24] A. Handa, V. Pătrăucean, S. Stent, and R. Cipolla, "SceneNet: An annotated model generator for indoor scene understanding," in *Proc. IEEE Int. Conf. Robot. Automat.*, 2016, pp. 5737–5743.

[25] H. Fu et al., "3D-front: 3D furnished rooms with layouts and semantics," in *Proc. IEEE/CVF Int. Conf. Comput. Vis.*, 2021, pp. 10933–10942.

[26] A. Singh, J. Sha, K. S. Narayan, T. Achim, and P. Abbeel, "BigBIRD: A large-scale 3D database of object instances," in *Proc. IEEE Int. Conf. Robot. Automat.*, 2014, pp. 509–516.

[27] B. Calli et al., "Yale-CMU-Berkeley dataset for robotic manipulation research," *Int. J. Robot. Res.*, vol. 36, no. 3, pp. 261–268, 2017.

[28] A. Kasper, Z. Xue, and R. Dillmann, "The kit object models database: An object model database for object recognition, localization and manipulation in service robotics," *Int. J. Robot. Res.*, vol. 31, no. 8, pp. 927–934, 2012.

[29] J. Straub et al., "The replica dataset: A digital replica of indoor spaces," 2019, *arXiv: 1906.05797*.

[30] A. Chang et al., "Matterport3D: Learning from RGB-D data in indoor environments," *Int. Conf. 3D Vis.*, 2017, pp. 667–676.

[31] M. Berger, J. A. Levine, L. G. Nonato, G. Taubin, and C. T. Silva, "A benchmark for surface reconstruction," *ACM Trans. Graph.*, vol. 32, no. 2, pp. 1–17, 2013.

[32] M. Botsch, L. Kobbelt, M. Pauly, P. Alliez, and B. Lévy, *Polygon Mesh Processing*. Boca Raton, FL, USA: AK Peters / CRC Press, Sep. 2010.

[33] E. Tretschk, A. Tewari, V. Golyanik, M. Zollhöfer, C. Stoll, and C. Theobalt, "PatchNets: Patch-based generalizable deep implicit 3D shape representations," in *Proc. Eur. Conf. Comput. Vis.*, Springer, 2020, pp. 293–309.

[34] R. Chabra et al., "Deep local shapes: Learning local SDF priors for detailed 3D reconstruction," in *Proc. Eur. Conf. Comput. Vis.*, Cham: Springer International Publishing, 2020, pp. 608–625.

[35] S. Peng, M. Niemeyer, L. Mescheder, M. Pollefeys, and A. Geiger, "Convolutional occupancy networks," in *Proc. Eur. Conf. Comput. Vis.*, Springer International Publishing, 2020, pp. 523–540.

[36] J. Tang, J. Lei, D. Xu, F. Ma, K. Jia, and L. Zhang, "SA-ConvONet: Sign-agnostic optimization of convolutional occupancy networks," in *Proc. IEEE/CVF Int. Conf. Comput. Vis.*, 2021, pp. 6504–6513.

[37] A. Gropp, L. Yariv, N. Haim, M. Atzmon, and Y. Lipman, "Implicit geometric regularization for learning shapes," in *Proc. Mach. Learn. Syst.*, 2020, pp. 3569–3579.

[38] M. Kazhdan, M. Bolitho, and H. Hoppe, "Poisson surface reconstruction," in *Proc. 4th Eurograph. Symp. Geometry Process.*, 2006, pp. 61–70.

[39] M. Kazhdan and H. Hoppe, "Screened Poisson surface reconstruction," *ACM Trans. Graph.*, vol. 32, no. 3, pp. 1–13, 2013.

[40] H. Edelsbrunner and N. R. Shah, "Triangulating topological spaces," in *Proc. 10th Annu. Symp. Comput. Geometry*, 1994, pp. 285–292.

[41] D. Cohen-Steiner and F. Da, "A greedy delaunay-based surface reconstruction algorithm," *Vis. Comput.*, vol. 20, no. 1, pp. 4–16, 2004.

[42] F. Bernardini, J. Mittleman, H. Rushmeier, C. Silva, and G. Taubin, "The ball-pivoting algorithm for surface reconstruction," *IEEE Trans. Vis. Comput. Graphics*, vol. 5, no. 4, pp. 349–359, Fourth Quarter 1999.

[43] D. Levin, "Mesh-independent surface interpolation," in *Proc. Geometric Model. Sci. Vis.*, Berlin, Germany: Springer, 2004, pp. 37–49.

[44] S. Peng, C. M. Jiang, Y. Liao, M. Niemeyer, M. Pollefeys, and A. Geiger, "Shape as points: A differentiable poisson solver," in *Proc. Adv. Neural Inf. Process. Syst.*, 2021, pp. 13032–13044.

[45] M. Eck and H. Hoppe, "Automatic reconstruction of b-spline surfaces of arbitrary topological type," in *Proc. 23rd Annu. Conf. Comput. Graph. Interactive Techn.*, 1996, pp. 325–334.

[46] Y. He and H. Qin, "Surface reconstruction with triangular b-splines," in *Proc. IEEE Geometric Model. Process.*, 2004, pp. 279–287.

[47] G. Sharma, D. Liu, S. Maji, E. Kalogerakis, S. Chaudhuri, and R. Měch, "ParSeNet: A parametric surface fitting network for 3D point clouds," in *Proc. Eur. Conf. Comput. Vis.*, 2020, pp. 261–276.

[48] N. Leal, E. Leal, and J. W. Branch, "Simple method for constructing NURBS surfaces from unorganized points," in *Proc. 19th Int. Meshing Roundtable*, Springer, 2010, pp. 161–175.

Authorized licensed use limited to: WUHAN UNIVERSITY OF TECHNOLOGY. Downloaded on October 10,2026 at 01:28:46 UTC from IEEE Xplore. Restrictions apply.

[49] A. Hashemian and S. F. Hosseini, "An integrated fitting and fairing approach for object reconstruction using smooth NURBS curves and surfaces," *Comput. Math. Appl.*, vol. 76, no. 7, pp. 1555–1575, 2018.

[50] R. Brüel-Gabrielsson, V. Ganapathi-Subramanian, P. Skraba, and L. J. Guibas, "Topology-aware surface reconstruction for point clouds," *Comput. Graph. Forum*, vol. 39, no. 5, pp. 197–207, 2020.

[51] D. Wang, "An efficient iterative method for reconstructing surface from point clouds," *J. Sci. Comput.*, vol. 87, no. 1, 2021, Art. no. 38.

[52] S. Lin, D. Xiao, Z. Shi, and B. Wang, "Surface reconstruction from point clouds without normals by parametrizing the Gauss formula," *ACM Trans. Graph.*, vol. 42, no. 2, pp. 1–19, 2022.

[53] J. C. Carr et al., "Reconstruction and representation of 3D objects with radial basis functions," in *Proc. 28th Annu. Conf. Comput. Graph. Interactive Techn.*, 2001, pp. 67–76.

[54] M. Kazhdan, "Reconstruction of solid models from oriented point sets," in *Proc. 3rd Eurographics Symp. Geometry Process.*, 2005, pp. 73–es.

[55] J. Manson, G. Petrova, and S. Schaefer, "Streaming surface reconstruction using wavelets," *Comput. Graph. Forum*, vol. 27, no. 5, pp. 1411–1420, 2008.

[56] Y. He, S. H. Kang, and H. Liu, "Curvature regularized surface reconstruction from point clouds," *SIAM J. Imag. Sci.*, vol. 13, no. 4, pp. 1834–1859, 2020.

[57] M. Alexa, J. Behr, D. Cohen-Or, S. Fleishman, D. Levin, and C. T. Silva, "Point set surfaces," in *Proc. Conf. Visual.*, 2001, pp. 21–28.

[58] A. Adamson and M. Alexa, "Approximating and intersecting surfaces from points," in *Proc. Eurographics/ACM SIGGRAPH Symp. Geometry Process.*, 2003, pp. 230–239.

[59] G. Guennebaud and M. Gross, "Algebraic point set surfaces," *ACM Trans. Graph.*, vol. 26, no. 3, pp. 23–es, Jul. 2007.

[60] M. Alexa, J. Behr, D. Cohen-Or, S. Fleishman, D. Levin, and C. T. Silva, "Computing and rendering point set surfaces," *IEEE Trans. Vis. Comput. Graphics*, vol. 9, no. 1, pp. 3–15, First Quarter, 2003.

[61] S. Fleishman, D. Cohen-Or, and C. T. Silva, "Robust moving least-squares fitting with sharp features," *ACM Trans. Graph.*, vol. 24, no. 3, pp. 544–552, 2005.

[62] R. Kolluri, "Provably good moving least squares," *ACM Trans. Algorithms*, vol. 4, no. 2, pp. 1–25, 2008.

[63] A. C. Öztireli, G. Guennebaud, and M. Gross, "Feature preserving point set surfaces based on non-linear kernel regression," *Comput. Graph. Forum*, vol. 28, no. 2, pp. 493–501, 2009.

[64] Z.-Q. Cheng, Y.-Z. Wang, B. Li, K. Xu, G. Dang, and S.-Y. Jin, "A survey of methods for moving least squares surfaces," in *Proc. 5th Eurograph./IEEE VGTC Conf. Point-Based Graph.*, 2008, pp. 9–23.

[65] R. Schnabel, R. Wahl, and R. Klein, "Efficient RANSAC for point-cloud shape detection," *Comput. Graph. Forum*, vol. 26, no. 2, pp. 214–226, 2007.

[66] L. Nan and P. Wonka, "PolyFit: Polygonal surface reconstruction from point clouds," in *Proc. IEEE Int. Conf. Comput. Vis.*, 2017, pp. 2353–2361.

[67] Z. Zhu et al., "PDE patch-based surface reconstruction from point clouds," *J. Comput. Sci.*, vol. 61, 2022, Art. no. 101647.

[68] Y. Li, A. Dai, L. Guibas, and M. Nießner, "Database-assisted object retrieval for real-time 3D reconstruction," *Comput. Graph. Forum*, vol. 34, no. 2, pp. 435–446, 2015.

[69] Y. M. Kim, N. J. Mitra, Q. Huang, and L. Guibas, "Guided real-time scanning of indoor objects," *Comput. Graph. Forum*, vol. 32, no. 7, pp. 177–186, 2013.

[70] L. Nan, K. Xie, and A. Sharf, "A search-classify approach for cluttered indoor scene understanding," *ACM Trans. Graph.*, vol. 31, no. 6, pp. 1–10, 2012.

[71] Y. M. Kim, N. J. Mitra, D.-M. Yan, and L. Guibas, "Acquiring 3D indoor environments with variability and repetition," *ACM Trans. Graph.*, vol. 31, no. 6, pp. 1–11, 2012.

[72] M. Pauly, N. J. Mitra, J. Giesen, M. H. Gross, and L. J. Guibas, "Example-based 3D scan completion," in *Proc. Symp. Geometry Process.*, 2005, pp. 23–32.

[73] C.-H. Shen, H. Fu, K. Chen, and S.-M. Hu, "Structure recovery by part assembly," *ACM Trans. Graph.*, vol. 31, no. 6, pp. 1–11, 2012.

[74] D. Ulyanov, A. Vedaldi, and V. Lempitsky, "Deep image prior," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2018, pp. 9446–9454.

[75] F. Williams, T. Schneider, C. Silva, D. Zorin, J. Bruna, and D. Panozzo, "Deep geometric prior for surface reconstruction," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2019, pp. 10130–10139.

[76] R. Hanocka, G. Metzer, R. Giryes, and D. Cohen-Or, "Point2Mesh: A self-prior for deformable meshes," *ACM Trans. Graph.*, vol. 39, no. 4, Jul. 2020, Art. no. 126.

[77] W. Zhao, J. Lei, Y. Wen, J. Zhang, and K. Jia, "Sign-agnostic implicit learning of surface self-similarities for shape modeling and reconstruction from raw point clouds," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2021, pp. 10256–10265.

[78] R. Hanocka et al., "MeshCNN: A network with an edge," *ACM Trans. Graph.*, vol. 38, no. 4, pp. 1–12, 2019.

[79] M. Gadelha, R. Wang, and S. Maji, "Deep manifold prior," in *Proc. IEEE/CVF Int. Conf. Comput. Vis. Workshops*, 2021, pp. 1107–1116.

[80] M. Atzmon, N. Haim, L. Yariv, O. Israelov, H. Maron, and Y. Lipman, "Controlling neural level sets," in *Proc. Adv. Neural Inf. Process. Syst.*, 2019, Art. no. 182.

[81] J. Lei and K. Jia, "Analytic marching: An analytic meshing solution from deep implicit surface networks," in *Proc. Int. Conf. Mach. Learn.*, 2020, Art. no. 537.

[82] M. Atzmon and Y. Lipman, "SAL: Sign agnostic learning of shapes from raw data," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2020, pp. 2565–2574.

[83] M. Atzmon and Y. Lipman, "SALD: Sign agnostic learning with derivatives," in *Proc. Int. Conf. Learn. Representations*, 2021, pp. 1–14.

[84] A. Basher, M. Sarmad, and J. Boutellier, "LightSAL: Lightweight sign agnostic learning for implicit surface representation," 2021, *arXiv:2103.14273*.

[85] R. Zhu et al., "Semi-signed neural fitting for surface reconstruction from unoriented point clouds," 2022, *arXiv:2206.06715*.

[86] T. Davies, D. Nowrouzezahrai, and A. Jacobson, "On the effectiveness of weight-encoded neural implicit 3D shapes," 2021, *arXiv: 2009.09808*.

[87] F. Williams, M. Trager, J. Bruna, and D. Zorin, "Neural splines: Fitting 3D surfaces with infinitely-wide neural networks," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2021, pp. 9949–9958.

[88] Y. Liao, S. Donne, and A. Geiger, "Deep marching cubes: Learning explicit surface representations," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2018, pp. 2916–2925.

[89] P. Erler, P. Guerrero, S. Ohrhallinger, N. J. Mitra, and M. Wimmer, "Points2Surf learning implicit surfaces from point clouds," in *Proc. Eur. Conf. Comput. Vis.*, Springer, 2020, pp. 108–124.

[90] M. Yang, Y. Wen, W. Chen, Y. Chen, and K. Jia, "Deep optimized priors for 3D shape modeling and reconstruction," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2021, pp. 3269–3278.

[91] Z. Chen and H. Zhang, "Learning implicit fields for generative shape modeling," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2019, pp. 5939–5948.

[92] Y. Duan, H. Zhu, H. Wang, L. Yi, R. Nevatia, and L. J. Guibas, "Curriculum DeepSDF," in *Proc. Eur. Conf. Comput. Vis.*, Springer, 2020, pp. 51–67.

[93] S. Yao, F. Yang, Y. Cheng, and M. G. Mozerov, "3D shapes local geometry codes learning with SDF," in *Proc. IEEE/CVF Int. Conf. Comput. Vis.*, 2021, pp. 2110–2117.

[94] B. Guillard, F. Stella, and P. Fua, "Meshudf: Fast and differentiable meshing of unsigned distance field networks," in *Proc. Eur. Conf. Comput. Vis.*, 2022, pp. 576–592.

[95] S. Giebenhain and B. Goldluecke, "AIR-nets: An attention-based framework for locally conditioned implicit representations," in *Proc. Int. Conf. 3D Vis.*, 2021, pp. 1054–1064.

[96] X. Yan, L. Lin, N. J. Mitra, D. Lischinski, D. Cohen-Or, and H. Huang, "ShapeFormer: Transformer-based shape completion via sparse representation," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2022, pp. 6229–6239.

[97] A. Vaswani et al., "Attention is all you need," in *Proc. Adv. Neural Inf. Process. Syst.*, 2017, pp. 6000–6010.

[98] H. Zhao, L. Jiang, J. Jia, P. H. Torr, and V. Koltun, "Point transformer," in *Proc. IEEE/CVF Int. Conf. Comput. Vis.*, 2021, pp. 16259–16268.

[99] J. Tang, X. Han, M. Tan, X. Tong, and K. Jia, "SkeletonNet: A topology-preserving solution for learning mesh reconstruction of object surfaces from RGB images," *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 44, no. 10, pp. 6454–6471, Oct. 2022.

[100] J. Pan, X. Han, W. Chen, J. Tang, and K. Jia, "Deep mesh reconstruction from single RGB images via topology modification networks," in *Proc. IEEE/CVF Int. Conf. Comput. Vis.*, 2019, pp. 9963–9972.

[101] J. Chibane, T. Alldieck, and G. Pons-Moll, "Implicit functions in feature space for 3D shape reconstruction and completion," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2020, pp. 6970–6981.

Authorized licensed use limited to: WUHAN UNIVERSITY OF TECHNOLOGY. Downloaded on October 10,2026 at 01:28:46 UTC from IEEE Xplore. Restrictions apply.

[102] J. Chibane, A. Mir, and G. Pons-Moll, "Neural unsigned distance fields for implicit function learning," in *Proc. Adv. Neural Inf. Process. Syst.*, 2020, Art. no. 1816.
[103] Z. Mi, Y. Luo, and W. Tao, "SSRNet: Scalable 3D surface reconstruction network," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2020, pp. 970–979.
[104] T. Takikawa et al., "Neural geometric level of detail: Real-time rendering with implicit 3D shapes," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2021, pp. 11358–11367.
[105] A. Badki, O. Gallo, J. Kautz, and P. Sen, "Meshlet priors for 3D mesh reconstruction," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2020, pp. 2849–2858.
[106] C. R. Qi, H. Su, K. Mo, and L. J. Guibas, "PointNet: Deep learning on point sets for 3D classification and segmentation," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2017, pp. 652–660.
[107] M. Tatarchenko, J. Park, V. Koltun, and Q.-Y. Zhou, "Tangent convolutions for dense prediction in 3D," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2018, pp. 3887–3896.
[108] B. Ummenhofer and V. Koltun, "Adaptive surface reconstruction with multiscale convolutional kernels," in *Proc. IEEE/CVF Int. Conf. Comput. Vis.*, 2021, pp. 5651–5660.
[109] A. Boulch and R. Marlet, "POCO: Point convolution for surface reconstruction," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2022, pp. 6302–6314.
[110] H. Jiang, J. Cai, J. Zheng, and J. Xiao, "Neighborhood-based neural implicit reconstruction from point clouds," in *Proc. Int. Conf. 3D Vis.*, 2021, pp. 1259–1268.
[111] B. Ma, Y.-S. Liu, M. Zwicker, and Z. Han, "Surface reconstruction from point clouds by learning predictive context priors," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2022, pp. 6326–6337.
[112] D. Attali, J.-D. Boissonnat, and A. Lieutier, "Complexity of the delaunay triangulation of points on surfaces the smooth case," in *Proc. 19th Annu. Symp. Comput. Geometry*, 2003, pp. 201–210.
[113] J.-D. Boissonnat and F. Cazals, "Smooth surface reconstruction via natural neighbour interpolation of distance functions," *Comput. Geometry*, vol. 22, no. 1/3, pp. 185–203, 2002.
[114] F. Lafarge and P. Alliez, "Surface reconstruction through point set structuring," *Comput. Graph. Forum*, vol. 32, no. 2pt2, pp. 225–234, 2013.
[115] R. R. Paulsen, J. A. Bærentzen, and R. Larsen, "Markov random field surface reconstruction," *IEEE Trans. Vis. Comput. Graphics*, vol. 16, no. 4, pp. 636–646, Jul./Aug. 2010.
[116] J. Giesen, S. Spalinger, and B. Schölkopf, "Kernel methods for implicit surface modeling," in *Proc. Adv. Neural Inf. Process. Syst.*, 2005, pp. 1193–1200.
[117] F. Williams et al., "Neural fields as learnable kernels for 3D reconstruction," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2022, pp. 18500–18510.
[118] M. Baorui, H. Zhizhong, L. Yu-Shen, and Z. Matthias, "Neural-pull: Learning signed distance functions from point clouds by learning to pull space onto surfaces," in *Proc. Int. Conf. Mach. Learn.*, 2021, pp. 1–12.
[119] Y. Lipman, "Phase transitions, distance functions, and implicit neural representations," in *Proc. 38th Int. Conf. Mach. Learn.*, 2021, 2021, pp. 6702–6712.
[120] P.-S. Wang, Y. Liu, Y.-Q. Yang, and X. Tong, "Spline positional encoding for learning 3D implicit signed distance fields," in *Proc. 30th Int. Joint Conf. Artif. Intell.*, 2021, pp. 1091–1097.
[121] Z. Wang et al., "Neural-IMLS: Learning implicit moving least-squares for surface reconstruction from unoriented point clouds," 2021, *arXiv:2109.04398*.
[122] B. Ma, Y.-S. Liu, and Z. Han, "Reconstructing surfaces for sparse point clouds with on-surface priors," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2022, pp. 6315–6325.
[123] M.-J. Rakotosaona, P. Guerrero, N. Aigerman, N. J. Mitra, and M. Ovsjanikov, "Learning delaunay surface elements for mesh reconstruction," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2021, pp. 22–31.
[124] S.-L. Liu, H.-X. Guo, H. Pan, P.-S. Wang, X. Tong, and Y. Liu, "Deep implicit moving least-squares functions for 3D reconstruction," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2021, pp. 1788–1797.
[125] L. Li, M. Sung, A. Dubrovina, L. Yi, and L. J. Guibas, "Supervised fitting of geometric primitives to 3D point clouds," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2019, pp. 2652–2660.
[126] M. Liu, X. Zhang, and H. Su, "Meshing point clouds with predicted intrinsic-extrinsic ratio guidance," in *Proc. Eur. Conf. Comput. Vis.*, Springer, 2020, pp. 68–84.
[127] J. Gao, W. Chen, T. Xiang, A. Jacobson, M. McGuire, and S. Fidler, "Learning deformable tetrahedral meshes for 3D reconstruction," in *Proc. Adv. Neural Inf. Process. Syst.*, 2020, Art. no. 833.
[128] N. Wang, Y. Zhang, Z. Li, Y. Fu, W. Liu, and Y.-G. Jiang, "Pixel2Mesh: Generating 3D mesh models from single RGB images," in *Proc. Eur. Conf. Comput. Vis.*, 2018, pp. 52–67.
[129] H. Kato, Y. Ushiku, and T. Harada, "Neural 3D mesh renderer," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2018, pp. 3907–3916.
[130] D. Xiao, S. Lin, Z. Shi, and B. Wang, "Learning modified indicator functions for surface reconstruction," *Comput. Graph.*, vol. 102, pp. 309–319, 2022.
[131] E.-T. Lê, M. Sung, D. Ceylan, R. Mech, T. Boubekeur, and N. J. Mitra, "CPFN: Cascaded primitive fitting networks for high-resolution point clouds," in *Proc. IEEE/CVF Int. Conf. Comput. Vis.*, 2021, pp. 7457–7466.
[132] K. Genova, F. Cole, A. Sud, A. Sarna, and T. Funkhouser, "Local deep implicit functions for 3D shape," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit.*, 2020, pp. 4857–4866.
[133] Y. Siddiqui, J. Thies, F. Ma, Q. Shan, M. Nießner, and A. Dai, "Retrievalfuse: Neural 3D scene reconstruction with a database," in *Proc. Int. Conf. Comput. Vis.*, 2021, pp. 12548–12557.
[134] J. Rossignac, "Shape complexity," *Vis. Comput.*, vol. 21, no. 12, pp. 985–996, 2005.
[135] D. Stutz, "A formal definition of watertight meshes," 2018. Accessed: Dec. 2021. [Online]. Available: https://davidstutz.de/a-formal-definition-of-watertight-meshes
[136] J. Kontkanen and S. Laine, "Ambient occlusion fields," in *Proc. Symp. Interactive 3D Graph. Games*, 2005, pp. 41–48.
[137] M. Gschwandtner, R. Kwitt, A. Uhl, and W. Pree, "BlenSor: Blender sensor simulation toolbox," in *Proc. Int. Symp. Vis. Comput.*, Springer, 2011, pp. 199–208.
[138] L. Li, "Time-of-flight camera–An introduction," May 2014. [Online]. Available: https://www.ti.com/lit/wp/sloa190b/sloa190b.pdf
[139] E. W. Weisstein, "Euler angles," 2009. [Online]. Available: https://mathworld.wolfram.com
[140] J. Jiao, L. Yuan, W. Tang, Z. Deng, and Q. Wu, "A post-rectification approach of depth images of kinect v2 for 3D reconstruction of indoor scenes," *ISPRS Int. J. Geo- Inf.*, vol. 6, no. 11, p. 349, 2017.
[141] D. Girardeau-Montaut, "Cloudcompare (version 2.12.0) [GPL software]," Mar. 2022. [Online]. Available: http://www.cloudcompare.org
[142] R. B. Rusu, Z. C. Marton, N. Blodow, M. Dolha, and M. Beetz, "Towards 3D point cloud based object maps for household environments," *Robot. Auton. Syst.*, vol. 56, no. 11, pp. 927–941, 2008.
[143] F. Cazals and M. Pouget, "Estimating differential quantities using polynomial fitting of osculating jets," *Comput. Aided Geometric Des.*, vol. 22, no. 2, pp. 121–146, 2005.
[144] J. Yang, R. Li, Y. Xiao, and Z. Cao, "3D reconstruction from non-uniform point clouds via local hierarchical clustering," in *Proc. 9th Int. Conf. Digit. Image Process.*, SPIE, 2017, pp. 685–689.
[145] H. Fan, H. Su, and L. J. Guibas, "A point set generation network for 3D object reconstruction from a single image," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2017, pp. 605–613.
[146] A. Knapitsch, J. Park, Q.-Y. Zhou, and V. Koltun, "Tanks and temples: Benchmarking large-scale scene reconstruction," *ACM Trans. Graph.*, vol. 36, no. 4, pp. 1–13, 2017.
[147] R. Zhang, P. Isola, A. A. Efros, E. Shechtman, and O. Wang, "The unreasonable effectiveness of deep features as a perceptual metric," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, 2018, pp. 586–595.
[148] D.-Y. Chen, X.-P. Tian, Y.-T. Shen, and M. Ouhyoung, "On visual similarity based 3D model retrieval," *Comput. Graph. Forum*, vol. 22, no. 3, pp. 223–232, 2003.
[149] A. Fabri and S. Pion, "CGAL: The computational geometry algorithms library," in *Proc. 17th ACM SIGSPATIAL Int. Conf. Adv. Geographic Inf. Syst.*, 2009, pp. 538–539.
[150] P. Cignoni, M. Callieri, M. Corsini, M. Dellepiane, F. Ganovelli, and G. Ranzuglia, "MeshLab: An open-source mesh processing tool," in *Proc. Eurographics Italian Chapter Conf.*, V. Scarano, R. D. Chiara, and U. Erra, Eds., The Eurographics Association, 2008, pp. 129–136.

Authorized licensed use limited to: WUHAN UNIVERSITY OF TECHNOLOGY. Downloaded on October 10,2026 at 01:28:46 UTC from IEEE Xplore. Restrictions apply.



ZhangJin Huang received the graduate degree from the School of Electronic and Information Engineering, South China University of Technology, Guangzhou, China, in 2021. He is currently working toward the master's degree in electronic information with the South China University of Technology. His research interests include computer vision and machine learning.



Yuxin Wen is currently working toward the PhD degree in information and communication engineering with the School of Electronic and Information Engineering, South China University of Technology. His research interests are in computer vision and machine learning, with focus on deep learning shape modeling and reconstruction of objects and scenes.



ZiHao Wang is currently working toward the master's degree in electronic information with the School of Electronic and Information Engineering, South China University of Technology. His research interests include computer vision, depth sensor, and machine learning.



Jinjuan Ren received the BA degree from Fudan University, in 2001, the MPhil degree from the University of Hong Kong, in 2004, and the PhD degree from the University of Hong Kong, in 2009. She has been an associate professor with the University of Macau since 2015. She was an assistant professor with the University of Macau from 2009 to 2015. Her research areas include fintech, machine learning, and behavioral finance. She published papers in top journals such as *Management Science*. She is a CFA charter-holder.



Kui Jia received the BEng degree in marine engineering from Northwestern Polytechnical University, China, in 2001, the MEng degree in electrical and computer engineering from the National University of Singapore, in 2003, and the PhD degree in computer science from the Queen Mary University of London, London, U.K., in 2007. He is currently a professor with the School of Electronic and Information Engineering, South China University of Technology. His research interests are in computer vision and machine learning. His recent research focuses on theoretical deep learning and its applications to 3D vision. He has been serving as an associate editor for *IEEE Trans. on Image Processing* and *Transaction on Machine Learning Research*.

Authorized licensed use limited to: WUHAN UNIVERSITY OF TECHNOLOGY. Downloaded on October 10,2026 at 01:28:46 UTC from IEEE Xplore. Restrictions apply.